

# Statistik och dataanalys I – F13

Statistiska institutionen

HT2026

*Denna version 2026-09-28*

# Innehåll föreläsning 13

- **Slumpvariabler** och **sannolikhetsfördelningar**
- Sammanfatta sannolikhetsfördelningar – **väntevärde** och **varians**
- **Kontinuerliga slumpvariabler** – en första titt på **normalfördelningen**.
- **Räkna med slumpvariabler** – skift, skalning, linjärkombination och summor
- **Beroende slumpvariabler** – **korrelation** och **kovarians**

# Slumpvariabler

- En **slumpvariabel** mäter ett **numeriskt värde** från slumpmässigt försök.
  - ▶ en prick vid tärningskast  $\rightarrow 1$ , två prickar  $\rightarrow 2$ , ...
  - ▶  $X = \begin{cases} 0 & \text{om minusgrader} \\ 1 & \text{om plusgrader} \end{cases}$
- Vi skriver **slumpvariabler** med **stora bokstäver** som t ex  $X$  och deras numeriska **utfall** med **små bokstäver** som t ex  $x$ .
- Slumpvariabeln  $X = \{\text{"antal prickar"}\}$  fick utfallet  $x = 3$
- En slumpvariabel kan vara:
  - ▶ **Diskret**: utfallen går att räkna upp, t ex  $0, 1, 2, \dots$ .  
**Exempel**: Antal prickar på en tärning. Totalt antal slantsinglingar innan första "krona"  $0, 1, 2, \dots$ .
  - ▶ **Kontinuerlig**: utfallen går inte att räkna upp, alla värden i ett intervall är möjliga.  
**Exempel**: Temperatur, längd

# Sannolikhetsfördelning


- För en *diskret* slumpvariabel  $X$  har varje värde  $x$  som  $X$  kan anta en **sannolikhet**  $P(X = x)$  (eller bara  $P(x)$ ).
- **Sannolikhetsfördelningen** för  $X$  är sannolikheterna för alla möjliga utfall.
- Det gäller alltid att  $\sum_{\text{alla } x} P(x) = 1$ .

Summan är över alla möjliga värden för  $X$ .


|        |      |      |      |      |      |          |
|--------|------|------|------|------|------|----------|
| $x$    | 1    | 2    | 3    | 4    | 5    | $\Sigma$ |
| $P(x)$ | 0.10 | 0.25 | 0.40 | 0.20 | 0.05 | 1        |

# Sannolikhetsfördelning

- För en *kontinuerlig* slumpvariabel  $X$  används istället en *täthetsfunktion* för att beskriva fördelningen.
- Sannolikheten  $P(a \leq X \leq b)$  för två punkter  $a$  och  $b$  ges av arean under täthetsfunktionen mellan  $a$  och  $b$ .




Diskret slumpvariabel




Kontinuerlig slumpvariabel

# Fördelning av slumpvariabel - två tärningskast

- **Slumpvariabel:** Händelser  $\implies$  numeriska värden



# Fördelning av slumpvariabel - två tärningskast



# Väntevärde

- **Medelvärde**t för ett **stickprov** är

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n}x_1 + \frac{1}{n}x_2 + \dots + \frac{1}{n}x_n$$

- För en diskret slumpvariabel  $X$  med sannolikhetsfördelning  $P(X = x)$  är **väntevärdet** (**expected value**) av  $X$

$$E(X) = \sum_{\text{alla } x} x \cdot P(x).$$


Summan är över alla möjliga värden för  $X$ .

- Vi använder ofta grekiska bokstaven  $\mu$  för  $E(X)$ . Grekiska bokstaven för m, m som i **mean**.
- Mer utförligt: om  $X$  kan anta värdena  $\{x_1, x_2, \dots, x_m\}$  så är


$$E(X) = \sum_{i=1}^m x_i \cdot P(x_i)$$

# Väntevärde


- Väntevärde - sannolikhetsfördelningens **jämviktspunkt**.
- Medelvärdet  $\bar{x}$  påverkas mycket av extrema värden.
- Väntevärdet påverkas mycket av fördelningens 'svansar'.



Diskret slumpvariabel




Kontinuerlig symmetrisk  
slumpvariabel



Kontinuerlig skew  
slumpvariabel

# Förväntad vinst - trisslott

| vinst   | antal   | probs        |
|---------|---------|--------------|
| 0       | 4713000 | 0.7855000000 |
| 30      | 565563  | 0.0942605000 |
| 60      | 601056  | 0.1001760000 |
| 90      | 78000   | 0.0130000000 |
| 120     | 21600   | 0.0036000000 |
| 150     | 11280   | 0.0018800000 |
| 180     | 3600    | 0.0006000000 |
| 300     | 2790    | 0.0004650000 |
| 450     | 375     | 0.0000625000 |
| 500     | 600     | 0.0001000000 |
| 600     | 600     | 0.0001000000 |
| 750     | 150     | 0.0000250000 |
| 900     | 180     | 0.0000300000 |
| 1000    | 480     | 0.0000800000 |
| 1500    | 240     | 0.0000400000 |
| 2000    | 150     | 0.0000250000 |
| 2500    | 45      | 0.0000075000 |
| 5000    | 90      | 0.0000150000 |
| 10000   | 132     | 0.0000220000 |
| 20000   | 21      | 0.0000035000 |
| 50000   | 9       | 0.0000015000 |
| 100000  | 6       | 0.0000010000 |
| 200000  | 3       | 0.0000005000 |
| 265000  | 26      | 0.0000043333 |
| 1000000 | 1       | 0.0000001667 |
| 2765000 | 3       | 0.0000005000 |
| summa:  | 6000000 | 1            |





$$E(\text{vinst}) = 0 \cdot 0.7855 + 30 \cdot 0.0942605 + 60 \cdot 0.100176 + \dots + 2765000 \cdot 0.0000005 = 14.7 \text{ kr}$$

# Förväntad räntekostnad i slutet av 2023

- **Antag:** lån på 1 miljon. 1% högre ränta än styrräntan.

Diagram 5. Styrräntan med osäkerhetsintervall



| bankränta i % | sannolikhet | månadskostnad |
|---------------|-------------|---------------|
| 1             | 0.017       | 833           |
| 2             | 0.094       | 1667          |
| 3             | 0.252       | 2500          |
| 4             | 0.334       | 3333          |
| 5             | 0.219       | 4167          |
| 6             | 0.071       | 5000          |
| 7             | 0.011       | 5833          |
| 8             | 0.001       | 6667          |

$$E(\text{bankränta}) = 1 \cdot 0.017 + 2 \cdot 0.094 + \dots + 8 \cdot 0.001 \approx 3.9\%$$

$$E(\text{kostnad}) = 833 \cdot 0.017 + 1667 \cdot 0.094 + \dots + 6667 \cdot 0.001 \approx 3252 \text{ kr}$$

# Varians - ett mått på spridning

- Väntevärdet  $\mu$  är bara **ett sammanfattande** mått av sannolikhetsfördelningen.
- Två fördelningar kan ha samma väntevärde men skilja sig i utbredning.
- Vi vill därför ha ett mått på fördelningens **spridning**.
- Medelavvikelse från  $\mu$  som spridning?
  - ▶ Avvikelser från centrum  $x - \mu$ .
  - ▶ **Problem**: Negativa och positiva avvikelser tar ut varandra.
  - ▶ **Lösning**: Kvadrera avvikelserna  $(x - \mu)^2$  först.
- **Variansen** ( $\sigma^2$ ) för en slumpvariabel

$$Var(X) = \sum_{\text{alla } x} (x - \mu)^2 P(x)$$

- **Exempel**:  $X$  = räntekostnad.  $\mu = E(X) = 3252$  kr.

$$Var(X) = (833 - 3252)^2 \cdot 0.017 + (1667 - 3252)^2 \cdot 0.094 + \dots + (6667 - 3252)^2 \cdot 0.001 \approx 965553.1 \text{ kr}^2$$

# Standardavvikelse - ett mått på medelspridning

- **Variansen** ( $\sigma^2$ ) för en slumpvariabel

$$Var(X) = \sum_{\text{alla } x} (x - \mu)^2 P(x)$$

Variansen har enheten i kvadrat. Svårtolkat.

- **Standardavvikelsen** har samma enhet som slumpvariabeln.



$$\sigma = SD(X) = \sqrt{Var(X)}$$

- **Exempel:**  $X$  = räntekostnad. Standardavvikelsen betecknas  $\sigma$ .

$$\sigma = \sqrt{965553.1} \approx 982.63 \text{kr}$$



- En genomsnittlig avvikelse från väntevärdet är ca. 983 kr.

# Väntevärde och standardavvikelse






# Normalfördelning - 68-95-99.7% regeln

- **Normalfördelning**,  $X \sim N(\mu, \sigma)$ 
  - ▶ Väntevärde  $E(X) = \mu$
  - ▶ Standardavvikelse  $SD(X) = \sigma$
- **Parametrarna**  $\mu$  och  $\sigma$  är just väntevärdet och standardavvikelsen!
- **68-95-99.7** % regeln




# 68-95-99.7 % regeln



# Kontinuerliga slumpvariabler och täthetsfunktioner

- En **kontinuerlig slumpvariabel** kan anta vilka värden som helst, men  $P(X = x) = 0$  för alla  $x$ !
- **Täthetsfunktionen**  $f(x)$  ger *inte* sannolikheter direkt, men kan användas för att beräkna sannolikheter enligt

$$P(a \leq X \leq b) = \text{arean under } f(x) \text{ mellan } a \text{ och } b$$



Egenskaper som en täthetsfunktion måste ha är

- ▶  $f(x) \geq 0$  för alla  $x$  (och  $f(x) > 1$  möjligt).
- ▶ Hela arean under  $f(x)$  skall vara 1.
- **SDAIII**: beräkna arean under funktionen med integration.

# Normalfördelning - interaktivt

## Normalfördelningen

$\mu$  :  

$\sigma$  :  


Kvantil:  

Om  $X \sim N(0, 1)$  så gäller att

$$E(X) = \mu = 0.00$$

$$Var(X) = \sigma^2 = 1.00$$

$$P(X \leq -1.96) = 0.02500$$






# Median och interkvartilavstånd

- **Median**,  $m$ : värde med 50 % av sannolikhetsmassan till vänster.

$$P(X \leq m) = 0.5$$

- **10%-kvantil**: 10% av sannolikhetsmassan till vänster.
- **Kvartiler**: 25%, 50 %, 75%
- **Interkvartilavstånd (IQR)**: avstånd mellan 25%-kvartil och 75%-kvartil.



# Skifta slumpvariabler

- **Exempel:**  $X$  ränta i procent på mitt banklån,  $E(X) = 3.9\%$ .
- Sämre förhandlare: bankräntan  $2\%$  högre än min.
- Din ränta:  $Y = X + 2$ . Vi **skiftar/förskjuter** slumpvariabeln.
- Måste vi göra om alla beräkningar för dig? Nej.

$$E(Y) = E(X) + 2 = 3.9 + 2 = 5.9\%$$

## Väntevärde - skiftade slumpvariabler

$$E(X \pm c) = E(X) \pm c \quad \text{för godtycklig konstant } c$$

- Variansen **ändras inte** av ett skift.

## Varians - skiftade slumpvariabler

$$Var(X \pm c) = Var(X) \quad \text{för godtycklig konstant } c$$

# Skala slumpvariabler

- **Exempel:** får dra av 30% på skatten för räntekostnad.
- Räntekostnad efter skatt:  $Y = 0.7 \cdot X$ . Vi **skalar** slumpvariabeln.

## Väntevärde - skalning

$$E(aX) = a \cdot E(X) \quad \text{för godtycklig konstant } a$$

## Varians - skalning

$$Var(aX) = a^2 \cdot Var(X) \quad \text{för godtycklig konstant } a$$

## Standardavvikelse - skalning

$$SD(aX) = |a| \cdot SD(X) \quad \text{för godtycklig konstant } a$$

- $E(Y) = E(0.7 \cdot X) = 0.7 \cdot E(X) = 0.7 \cdot 3252 = 2276.4$  kr
- $SD(Y) = SD(0.7 \cdot X) = |0.7| \cdot SD(X) = 0.7 \cdot 982.63 \approx 687.84$  kr

# Linjära transformationer av slumpvariabler

- **Linjär transformation** av slumpvariabel = **skift och skalning**.

$$Y = c + aX$$

Väntevärde - linjär transformation

$$E(c + aX) = c + aE(X) \quad \text{för konstanter } a \text{ och } c$$

Varians - linjär transformation

$$Var(c + aX) = a^2 \cdot Var(X) \quad \text{för konstanter } a \text{ och } c$$

- **Exempel:** ett företags produktionskostnader
  - ▶  $X$  antal efterfrågade enheter (slumpvariabel).
  - ▶ Fast produktionskostnad  $c$
  - ▶ Rörlig produktionskostnad per enhet  $a$
  - ▶ Produktionskostnad:  $Y = c + aX$

# Standardisering

- Om  $X$  har väntevärde  $\mu$  och standardavvikelse  $\sigma$  så gäller att den **standardiserade** slumpvariabeln  $Z = (X - \mu)/\sigma$  har väntevärde 0 och standardavvikelse 1.
- Om  $X$  är normalfördelad, dvs  $X \sim N(\mu, \sigma)$ , så gäller *dessutom* att  $Z$  *också* är normalfördelad, dvs

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

- Genom **skift** och **skalning** går vi alltså från  $N(\mu, \sigma)$  till  $N(0, 1)$ .
- Sannolikheter för  $X \sim N(\mu, \sigma)$  kan beräknas mha standardisering:


$$\begin{aligned} P(X \leq x) &= P(X - \mu \leq x - \mu) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) \\ &= P\left(Z \leq \frac{x - \mu}{\sigma}\right) \end{aligned}$$

# Normalfördelning – Z-tabell

## Normalfördelning

Tabellen ger sannolikheten  $\Phi(z) = P(Z \leq z)$  för olika  $z$  där  $Z$  är standardnormal,  $Z \sim N(0, 1)$ .

Sannolikheter i den vänstra svansen fås genom symmetri:  $P(Z \leq -z) = 1 - P(Z \leq z)$ .




Andra decimalen i  $z$

|     | 0.00   | 0.01   | 0.02   | 0.03   | 0.04   | 0.05   | 0.06   | 0.07   | 0.08   | 0.09   |
|-----|--------|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 0.0 | 0.5000 | 0.5040 | 0.5080 | 0.5120 | 0.5160 | 0.5199 | 0.5239 | 0.5279 | 0.5319 | 0.5359 |
| 0.1 | 0.5398 | 0.5438 | 0.5478 | 0.5517 | 0.5557 | 0.5596 | 0.5636 | 0.5675 | 0.5714 | 0.5753 |
| 0.2 | 0.5793 | 0.5832 | 0.5871 | 0.5910 | 0.5948 | 0.5987 | 0.6026 | 0.6064 | 0.6103 | 0.6141 |
| 0.3 | 0.6179 | 0.6217 | 0.6255 | 0.6293 | 0.6331 | 0.6368 | 0.6406 | 0.6443 | 0.6480 | 0.6517 |
| 0.4 | 0.6554 | 0.6591 | 0.6628 | 0.6664 | 0.6700 | 0.6736 | 0.6772 | 0.6808 | 0.6844 | 0.6879 |
| 0.5 | 0.6915 | 0.6950 | 0.6985 | 0.7019 | 0.7054 | 0.7088 | 0.7123 | 0.7157 | 0.7190 | 0.7224 |
| 0.6 | 0.7257 | 0.7291 | 0.7324 | 0.7357 | 0.7389 | 0.7422 | 0.7454 | 0.7486 | 0.7517 | 0.7549 |
| 0.7 | 0.7580 | 0.7611 | 0.7642 | 0.7673 | 0.7704 | 0.7734 | 0.7764 | 0.7794 | 0.7823 | 0.7852 |
| 0.8 | 0.7881 | 0.7910 | 0.7939 | 0.7967 | 0.7995 | 0.8023 | 0.8051 | 0.8078 | 0.8106 | 0.8133 |
| 0.9 | 0.8159 | 0.8186 | 0.8212 | 0.8238 | 0.8264 | 0.8289 | 0.8315 | 0.8340 | 0.8365 | 0.8389 |
| 1.0 | 0.8413 | 0.8438 | 0.8461 | 0.8485 | 0.8508 | 0.8531 | 0.8554 | 0.8577 | 0.8599 | 0.8621 |
| 1.1 | 0.8643 | 0.8665 | 0.8686 | 0.8708 | 0.8729 | 0.8749 | 0.8770 | 0.8790 | 0.8810 | 0.8830 |
| 1.2 | 0.8849 | 0.8869 | 0.8888 | 0.8907 | 0.8925 | 0.8944 | 0.8962 | 0.8980 | 0.8997 | 0.9015 |
| 1.3 | 0.9032 | 0.9049 | 0.9066 | 0.9082 | 0.9099 | 0.9115 | 0.9131 | 0.9147 | 0.9162 | 0.9177 |
| 1.4 | 0.9192 | 0.9207 | 0.9222 | 0.9236 | 0.9251 | 0.9265 | 0.9279 | 0.9292 | 0.9306 | 0.9319 |
| 1.5 | 0.9332 | 0.9345 | 0.9357 | 0.9370 | 0.9382 | 0.9394 | 0.9406 | 0.9418 | 0.9429 | 0.9441 |
| 1.6 | 0.9452 | 0.9463 | 0.9474 | 0.9484 | 0.9495 | 0.9505 | 0.9515 | 0.9525 | 0.9535 | 0.9545 |
| 1.7 | 0.9554 | 0.9564 | 0.9573 | 0.9582 | 0.9591 | 0.9599 | 0.9608 | 0.9616 | 0.9625 | 0.9633 |
| 1.8 | 0.9641 | 0.9649 | 0.9656 | 0.9664 | 0.9671 | 0.9678 | 0.9686 | 0.9693 | 0.9699 | 0.9706 |
| 1.9 | 0.9713 | 0.9719 | 0.9726 | 0.9732 | 0.9738 | 0.9744 | 0.9750 | 0.9756 | 0.9761 | 0.9767 |
| 2.0 | 0.9772 | 0.9778 | 0.9783 | 0.9788 | 0.9793 | 0.9798 | 0.9803 | 0.9808 | 0.9812 | 0.9817 |
| 2.1 | 0.9821 | 0.9826 | 0.9830 | 0.9834 | 0.9838 | 0.9842 | 0.9846 | 0.9850 | 0.9854 | 0.9857 |
| 2.2 | 0.9861 | 0.9864 | 0.9868 | 0.9871 | 0.9875 | 0.9878 | 0.9881 | 0.9884 | 0.9887 | 0.9890 |
| 2.3 | 0.9893 | 0.9896 | 0.9898 | 0.9901 | 0.9904 | 0.9906 | 0.9909 | 0.9911 | 0.9913 | 0.9916 |
| 2.4 | 0.9918 | 0.9920 | 0.9922 | 0.9925 | 0.9927 | 0.9929 | 0.9931 | 0.9932 | 0.9934 | 0.9936 |
| 2.5 | 0.9938 | 0.9940 | 0.9941 | 0.9943 | 0.9945 | 0.9946 | 0.9948 | 0.9949 | 0.9951 | 0.9952 |

# Standardisering

- **Exempel:**  $X \sim N(2, 3)$ , vad är sannolikheten att  $X \leq 5$ ?

$$P(X \leq 5) = P\left(\frac{X - 2}{3} \leq \frac{5 - 2}{3}\right) = P(Z \leq 1) = 0.841$$



# Normalfördelning i R

- $X \sim N(\mu, \sigma)$

| Beräkning     | R kommando                                      |
|---------------|-------------------------------------------------|
| $f(2)$        | <code>dnorm(x = 2, mean = 1, sd = 1.5)</code>   |
| $P(X \leq 2)$ | <code>pnorm(q = 2, mean = 1, sd = 1.5)</code>   |
| Kvantil       | <code>qnorm(p = 0.5, mean = 1, sd = 1.5)</code> |
| 10 slumpstal  | <code>rnorm(n = 10, mean = 1, sd = 1.5)</code>  |

# Väntevärde – summa av slumpvariabler

- $X$  och  $Y$  är två olika slumpvaribler
  - ▶  $X$  antal prickar på 1:a tärningen
  - ▶  $Y$  antal prickar på 2:a tärningen
  - ▶  $X + Y$  = totalt antal prickar på båda tärningarna.

## Väntevärde - summa av slumpvariabler

$$E(X + Y) = E(X) + E(Y)$$

# Varians – summa av oberoende slumpvariabler

- För **variansen** måste vi vara försiktiga med eventuella **beroenden mellan variabler**.
- **Vadslagning:**
  - ▶  $X$  är din vinst/förlust i ett vad.
  - ▶  $Y$  är din motståndares vinst/förlust.
  - ▶  $X + Y = 0$ , dvs. har ingen varians alls! Perfekt beroende.
- **Aktieportfölj:**
  - ▶  $X$  är avkastningen för en aktie.
  - ▶  $Y$  är avkastning för en annan aktie.
  - ▶ Total avkastning:  $X + Y$ . Varians?
- Om vi antar att  $X$  och  $Y$  är **oberoende** blir variansen enkel:

Varians - summa av oberoende slumpvariabler

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

# Väntevärde och varians – många oberoende variabler

- Låt  $X_1, X_2$  och  $X_3$  vara tre oberoende slumpvariabler.

$$E(X_1 + X_2 + X_3) = E(X_1) + E(X_2) + E(X_3)$$

$$Var(X_1 + X_2 + X_3) = Var(X_1) + Var(X_2) + Var(X_3)$$

Väntevärde - summa av slumpvariabler

$$E(X_1 + X_2 + \dots + X_n) = E(X_1) + E(X_2) + \dots + E(X_n)$$

Varians - summa av **oberoende** slumpvariabler

$$Var(X_1 + X_2 + \dots + X_n) = Var(X_1) + Var(X_2) + \dots + Var(X_n)$$

# Simultanfördelning – två diskreta variabler

- $X$  och  $Y$  diskreta variabler, t. ex.
  - ▶  $X$  = antal mål som hemmalaget gör
  - ▶  $Y$  = antal mål som bortalaget gör


|            |   | Y    |      |      | Marginal X |
|------------|---|------|------|------|------------|
|            |   | 0    | 1    | 2    |            |
| X          | 0 | 0.25 | 0.05 | 0.02 | 0.32       |
|            | 1 | 0.1  | 0.23 | 0.05 | 0.38       |
|            | 2 | 0.05 | 0.1  | 0.15 | 0.3        |
| Marginal Y |   | 0.4  | 0.38 | 0.22 | 1          |

Varje marginalfördelning måste också summera till 1.

Summan av alla simultansannolikheter måste vara 1

Simultanfördelning  $P(x,y)$

punkternas storlek representerar den simultana sannolikheten  $P(x,y)$



# Simultanfördelning – två diskreta variabler

|            |   | Y    |      |      |            |
|------------|---|------|------|------|------------|
|            |   | 0    | 1    | 2    | Marginal X |
| X          | 0 | 0.25 | 0.05 | 0.02 | 0.32       |
|            | 1 | 0.1  | 0.23 | 0.05 | 0.38       |
|            | 2 | 0.05 | 0.1  | 0.15 | 0.3        |
| Marginal Y |   | 0.4  | 0.38 | 0.22 | 1          |

- Väntevärden

$$E(X) = \sum_{\text{alla } x} x \cdot P(x) = 0 \cdot 0.32 + 1 \cdot 0.38 + 2 \cdot 0.30 = 0.98$$

$$E(Y) = \sum_{\text{alla } y} y \cdot P(y) = 0 \cdot 0.40 + 1 \cdot 0.38 + 2 \cdot 0.22 = 0.82$$

- Varianser

$$Var(X) = \sum_{\text{alla } x} (x - E(X))^2 \cdot P(x) = (0 - 0.98)^2 \cdot 0.32 + (1 - 0.98)^2 \cdot 0.38 + (2 - 0.98)^2 \cdot 0.30 = 0.62$$

$$Var(Y) = \sum_{\text{alla } y} (y - E(Y))^2 \cdot P(y) = (0 - 0.82)^2 \cdot 0.40 + (1 - 0.82)^2 \cdot 0.38 + (2 - 0.82)^2 \cdot 0.22 = 0.59$$

# Simultanfördelning – två diskreta variabler

|            |   | Y    |      |      |            |
|------------|---|------|------|------|------------|
|            |   | 0    | 1    | 2    | Marginal X |
| X          | 0 | 0.25 | 0.05 | 0.02 | 0.32       |
|            | 1 | 0.1  | 0.23 | 0.05 | 0.38       |
|            | 2 | 0.05 | 0.1  | 0.15 | 0.3        |
| Marginal Y |   | 0.4  | 0.38 | 0.22 | 1          |

- **Kovarians** mellan  $X$  och  $Y$

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))] = \sum_{\text{alla } (x,y) \text{ par}} (x - E(X))(y - E(Y)) \cdot P(x, y)$$

Här

$$\begin{aligned} Cov(X, Y) &= (0 - 0.98)(0 - 0.82) \cdot 0.25 + (1 - 0.98)(0 - 0.82) \cdot 0.10 \\ &\quad + (2 - 0.98)(0 - 0.82) \cdot 0.05 + \dots + (2 - 0.98)(2 - 0.82) \cdot 0.15 = 0.326 \end{aligned}$$


- **Korrelation** mellan  $X$  och  $Y$

$$Corr(X, Y) = \frac{Cov(X, Y)}{SD(X) \cdot SD(Y)} = \frac{0.326}{\sqrt{0.62}\sqrt{0.588}} = 0.54$$

# Korrelation kontinuerliga variabler – Stickprov

- **Korrelation:** linjärt beroende mellan variabler.


Positiv korrelation - flest datapunkter med  
positiva bidrag till täljaren i korrelationen



$$(x_i - \bar{x})(y_i - \bar{y}) > 0$$

$$(x_i - \bar{x})(y_i - \bar{y}) < 0$$

Negativ korrelation - flest datapunkter med  
negativa bidrag till täljaren i korrelationen



$$(x_i - \bar{x})(y_i - \bar{y}) > 0$$

$$(x_i - \bar{x})(y_i - \bar{y}) < 0$$


- **Stickprovskovarians:**

$$s_{xy} = Cov(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

# Korrelation kontinuerliga variabler - Sannolikhetsmodell

- Låt  $X$  ha väntevärde  $\mu$  och  $Y$  väntevärde  $\nu$
- **Kovarians**: linjärt beroende mellan slumpvariabler.

$$Cov(X, Y) = E((X - \mu)(Y - \nu))$$



- **Korrelation** ( $-1 \leq Corr(X, Y) \leq 1$ )

$$Corr(X, Y) = \rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \cdot \sigma_Y}$$

# Variansen av en summan av beroende variabler

Varians - summa av **beroende** slumpvariabler

$$Var(X + Y) = Var(X) + Var(Y) + 2 Cov(X, Y)$$

- **Positiv kovarians** – **variansen** för summan **större** än vid oberoende.
- **Negativ kovarians** – **variansen** för summan **mindre** än vid oberoende
- Säker aktieportfölj: välj aktier vars priser tenderar att röra sig i olika riktningar. Negativ kovarians.
- Verifiera gärna t ex

$$Var(X + Y) = Var(X) + Var(Y) + 2 Cov(X, Y)$$

i exemplet med mål ovan!

# Sammanfattning

- En *diskret slumpvariabel*  $X$  har *sannolikhetsfunktion*  $P(x) = P(X = x)$  ( $x$  är möjliga utfall för  $X$ ).
- En *kontinuerlig slumpvariabel*  $X$  har *täthetsfunktion*  $f(x)$
- *Väntevärde*:  $E(X) = \sum_{\text{alla } x} x P(x)$  [kalla det  $\mu$ ]
- *Varians*:  $Var(X) = E[(X - \mu)^2] = E(X^2) - \mu^2 = \sum_{\text{alla } x} (x - \mu)^2 P(x)$
- *Standardavvikelse*:  $SD(X) = \sqrt{Var(X)}$
- $E(\sum_{k=1}^n a_k X_k) = \sum_{k=1}^n a_k E(X_k)$
- $Var(\sum_{k=1}^n a_k X_k) = \sum_{k=1}^n a_k^2 Var(X_k)$  för *oberoende* s.v.  $X_1, \dots, X_n$
- *Kovarians*:  $Cov(X, Y) = E[(X - \mu)(Y - \nu)] = E(XY) - \mu\nu = \sum_{\text{alla } (x,y)} (x - \mu)(y - \nu) P(x, y)$
- $Var(aX + bY) = a^2 Var(X) + b^2 Var(Y) + 2ab Cov(X, Y)$  [alltid]
- $Var(X) = Cov(X, X)$
- *Korrelation*:  $Corr(X, Y) = Cov(X, Y) / [SD(X) SD(Y)]$   
[ $-1 \leq Corr \leq +1$ ]

# Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo VT 2026 och Tobias Rydén HT 2026.