

Statistik och dataanalys I - F14

Statistiska institutionen

VT2026

Denna version: 2026-09-21

Innehåll föreläsning 14

- **Bernoulliförsök**
- **Geometrisk fördelning**
- **Binomialfördelning**

Bernoulliförsök

- **Bernoulliförsök**

- 1 **Två möjliga utfall:** lyckas/misslyckas.
- 2 **Samma sannolikhet** för att lyckas, p , i alla försök.
- 3 **Oberoende försök**

- **Exempel:** Slantsingling

- ▶ Lyckas = Krona, Misslyckas = Klave.
- ▶ Sannolikhet $p = 0.5$ för korrekt mynt.
- ▶ Utfall på en singling beror inte på andra singlar.




Bernoulliförsök fortsättning

- Lyckas/Misslyckas är bara en benämning utan någon mänsklig värdering.
- Samma med positivt/negativt resultat.
- Död/Levande. Hel/Trasig. Spam/Inte spam.
- Utan återläggning $\Rightarrow$ inte samma p i olika försök:
 - ▶ $P(1:a \text{ kortet spader}) = 13/52 = 1/4$.
 - ▶ $P(2:a \text{ kortet spader}) = 12/51$ om 1:a spader *men* $13/51$ om 1:a hjärter/ruter/klöver.
 - ▶ Vi bryter emot både regel 2 och 3 på föregående sida.

Motivation – regression med binära y -variabler

- **Bernoulli-fördelning** med samma sannolikhet p .
- Spamdata: lära oss om $p = P(\text{spam})$ från data. $\hat{p} = 0.9$
- Spam-filter: ska datorn skicka just detta mejl till skräpkorgen?
- **SDAII**: Logistisk regression där sannolikheten för spam p beror på förklarande variabler, som i linjär regression




Bernoullifördelning

- Två möjliga utfall: lyckad/misslyckad. **Binär variabel.**
- Vi kan koda **lyckat = 1, misslyckat = 0.**

$$X = \begin{cases} 1 & \text{om Bernoulli-försök lyckat} \\ 0 & \text{om Bernoulli-försök misslyckat} \end{cases}$$

$$P(X = x) = \begin{cases} p & \text{för } x = 1 \\ q = 1 - p & \text{för } x = 0 \end{cases}$$



Bernoullifördelning

- **Väntevärde** och **varians**

$$\begin{aligned} E(X) &= \mu = \sum_{\text{alla } x} x \cdot P(x) \\ &= 0 \cdot P(X = 0) + 1 \cdot P(X = 1) = 0 \cdot q + 1 \cdot p \\ &= p \end{aligned}$$

$$\begin{aligned} Var(X) &= \sum_{\text{alla } x} (x - \mu)^2 \cdot P(x) \\ &= (0 - p)^2 \cdot q + (1 - p)^2 \cdot p \\ &= p^2 q + q^2 p = pq \underbrace{(p + q)}_1 = pq \end{aligned}$$

Exempel - straffkast i basket

- **Situation:** En basketspelare skjuter ett straffkast.
 - ▶ Lyckas = träff, misslyckas = miss.
 - ▶ Sannolikheten att spelaren sätter kastet är $p = 0.8$.
 - ▶ Sannolikheten för att misslyckas är $q = 1 - p = 0.2$
- Slumpvariabeln X tar värdet 1 om spelaren träffar, och tar värdet 0 om spelaren missar.
 $P(X = 1) = p = 0.8$ och $P(X = 0) = q = 0.2$.
- **Väntevärde:** $E(X) = p = 0.8$.
 - ▶ *Tolkning:* I genomsnitt 0.8 poäng per kast.
- **Varians:** $Var(X) = pq = 0.8 \cdot 0.2 = 0.16$.
 - ▶ *Tolkning:* Ett mått på osäkerheten i utfallet av ett kast.

Geometrisk fördelning

- Email: **spam** eller **icke-spam**. Lyckas = icke-spam.

▶ $P(\text{icke-spam}) = p = 0.1, P(\text{spam}) = q = 1 - 0.1 = 0.9$

- Hur många mejl måste du öppna tills du får ditt första icke-spam?

$$P(\text{första icke-spam på 4:e mejlet}) =$$

$$= \overbrace{0.9 \cdot 0.9 \cdot 0.9}^{\text{multiplikation pga oberoende}} \cdot \underbrace{0.1}_{\text{icke-spam}} = 0.9^3 \cdot 0.1 = 0.0729$$

3 spam icke-spam

- Vad är sannolikheten för x st mejl tills första icke-spam?

$$P(\text{första icke-spam på } x\text{:te mejlet}) = 0.9^{x-1} \cdot 0.1$$

Geometrisk fördelning

- **Geometrisk slumpvariabel** från Bernoulliförsök

X = antal försök tills första lyckade inträffar?

- **Geometrisk fördelning**

$$P(X = x) = q^{x-1}p, \quad \text{för } x = 1, 2, \dots$$

- **Obs!** X inkluderar första lyckade försöket, så X kan inte vara 0. Wikipedia kallar detta för för-första-gången-fördelning
- En geometrisk slumpvariabel X har väntevärde $1/p$ och varians $q/p^2 = (1 - p)/p^2$.

Geometrisk fördelning

Geometrisk fördelning


p : 
Kvantil: 

Om $X \sim \text{Geo}(0.5)$ så gäller att

$$E(X) = \frac{1}{p} = 2.00$$

$$\text{Var}(X) = \frac{1-p}{p^2} = 0.250$$

$$P(X \leq 3) = 0.8750$$



Geometrisk fördelning i R

- $X \sim \text{Geom}(p = 0.4)$. Sannolikheten p kallas `prob` i R.

Beräkning	R kommando
$P(X = 2)$	<code>dgeom(x = 2, prob = 0.4)</code>
$P(X \leq 2)$	<code>pgeom(q = 2, prob = 0.4)</code>
Kvantil	<code>qgeom(p = 0.5, prob = 0.4)</code>
10 slumpstal	<code>rgeom(n = 10, prob = 0.4)</code>

- R använder Wikipedias definition av geometrisk fördelning. X räknar **antalet misslyckade försök innan** första lyckade.
Fix:

```
y = rgeom(n = 100, prob = 0.5) # y is number of trials BEFORE first success
x = y + 1                       # x is number of trials INCLUDING first success
```

- Se programkoden `geometric.R` på kurssidan.

Basketspelarens straffkast, forts

- Vi har samma basketspelare, men nu definierar vi ett "lyckat" försök som en miss.
 - ▶ Sannolikheten för att "lyckas" är nu $p = P(\text{Miss}) = 0.2$.
 - ▶ Sannolikheten för att "misslyckas" (dvs. att träffa) är $q = P(\text{Träff}) = 0.8$
- Y är antalet kast som krävs för att få den första **missen**.
- $E(Y) = 1/p = 1/0.2 = 5$
- **Tolkning:** I genomsnitt krävs $Y = 5$ kast innan spelaren missar för första gången.
- $Var(Y) = q/p^2 = 0.8/0.2^2 = 20$, så $SD(Y) = \sqrt{20} \approx 4.5$.
- **Tolkning:** Ganska stor osäkerhet kring när första missen kommer.

Binomialfördelning

- **Geometrisk** fördelning:

- ▶ Hur många Bernoulli-försök tills **första** lyckade?
- ▶ Antal försök är slumpmässigt.

- **Binomialfördelning:**

- ▶ Vi bestämmer *på förhand* att vi gör n Bernoulli-försök, och frågar: *hur många av dessa n försök lyckas?*
- ▶ Antal lyckade försök, X säg, är en slumpvariabel.
- ▶ **Totala antalet försök** n är alltså **förbestämt** och fixerat, men antalet lyckade är slumpmässigt.
- ▶ Fördelningen för X kallas en **binomialfördelning**.

- Vi skriver $X \sim \text{Bin}(n, p)$ och säger att: “ X är **binomialfördelad** med **parametrar** n och p .”

- Hur ser denna fördelning ut, dvs vad är $P(X = x)$ för $x = 0, 1, \dots, n$; vad är $E(X)$ och $\text{Var}(X)$?

Binomialfördelning

- Vi kan *representera* X som summan av n **oberoende Bernoullivariabler** $X_1, X_2, \dots, X_n$, dvs

$$X = X_1 + X_2 + \dots + X_n$$

- **Exempel 1:** $n = 3$ slantsinglingar med resultat: $X_1 = 1$ (krona första), $X_2 = 1$ (krona andra) och $X_3 = 0$ (klave tredje).

$$X = 1 + 1 + 0 = 2 \text{ st lyckade (krona).}$$

- **Exempel 2:** Observera $n = 5$ passerande bilar, Bernoullivariabler $X_1, \dots, X_5$ antar värdet 1 om en bil är vit, 0 annars.
- Resultat: $Y_1 = 1$ (vit bil), $Y_4 = 1$ (vit bil), övriga bilar inte vita.

$$\text{Slumpvariabel } X = \sum_{i=1}^n X_i \text{ antalet vita bilar.}$$

$$\text{Utfall } x = \sum_{i=1}^n x_i = 2 \text{ vita bilar.}$$

Binomialfördelning – väntevärde och varians

- Låt $X \sim \text{Bin}(n, p)$.
- Genom att använda representationen $X = X_1 + X_2 + \dots + X_n$ ovan och $E(X_k) = p$ för varje Bernoullivariabel får vi





$$\begin{aligned} E(X) &= E(X_1 + \dots + X_n) = E(X_1) + \dots + E(X_n) \\ &= \underbrace{p + p + \dots + p}_{n \text{ st}} = np \end{aligned}$$

- Eftersom Bernoullivariablerna X_k har $\text{Var}(X_k) = pq$ och dessutom är *oberoende* får vi

$$\begin{aligned} \text{Var}(X) &= \text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n) \\ &= \underbrace{pq + pq + \dots + pq}_{n \text{ st}} = npq \end{aligned}$$

- Alltså: $E(X) = np$ och $\text{Var}(X) = npq$.

Binomialfördelning



Binomialfördelningens sannolikheter

- För $X \sim \text{Bin}(n, p)$, vad är egentligen $P(X = x)$?
- Tag $n = 3$. Slh att få $\{1, 1, 0\}$ i $n = 3$ försök är $p \cdot p \cdot q = p^2q$.
- Det finns dock **flera sätt** att få $X = 2$ i $n = 3$ försök:

1:a försök	2:a försök	3:e försök	X	sannolikhet
1	1	0	2	p^2q
1	0	1	2	p^2q
0	1	1	2	p^2q

- Eftersom dessa tre olika sätt att få $X = 2$ är **disjunkta**:

$$P(X = 2) = 3p^2q$$

- På samma sätt

$$P(X = 0) = P(\{0, 0, 0\}) = 1 \cdot q^3$$

$$P(X = 1) = P(\{1, 0, 0\} \cup \{0, 1, 0\} \cup \{0, 0, 1\}) = 3 \cdot pq^2$$

$$P(X = 2) = P(\{1, 1, 0\} \cup \{1, 0, 1\} \cup \{0, 1, 1\}) = 3 \cdot p^2q$$

$$P(X = 3) = P(\{1, 1, 1\}) = 1 \cdot p^3$$

Binomialfördelningens sannolikheter

- **Sannolikhetsfördelning** för $X \sim \text{Bin}(3, p)$

x	0	1	2	3	
$P(x)$	q^3	$3pq^2$	$3p^2q$	p^3	

- Kontrollera att summan av alla sannolikheter är ett:

$$q^3 + 3pq^2 + 3p^2q + p^3 = (p + q)^3 = 1^3 = 1$$

- Allmänna fallet $X \sim \text{Bin}(n, p)$

$$P(X = x) = {}_nC_x \cdot p^x q^{n-x} = \frac{n!}{k!(n-k)!} p^x q^{n-x}$$

- ${}_nC_x$ är antalet sätt välja x st lyckade bland n försök; kallas en *binomialkoefficient*.

Binomialfördelning - interaktivt

Binomialfördelningen

n : 

p : 

Kvantil: 


Visa
normalapproximation ☐

Om $X \sim \text{Binom}(10, 0.5)$ så gäller att

$$E(X) = np = 5.00$$

$$\text{Var}(X) = np(1 - p) = 2.50$$

$$\text{Exakt: } P(X \leq 3) = 0.1719$$



Binomialfördelningen - exemplet med bilar

- **Exempel 2 (forts.):** observera $n = 5$ passerande bilar. Antag att sannolikheten att observera en vit bil (lyckat försök) är $p = 0.3$
- Vad är sannolikheten att vi observerar **exakt** 2 vita bilar, $P(X = 2)$, som i exemplet?

$$\begin{aligned} P(X = 2) &= {}_n C_x p^x q^{(n-x)} = \frac{n!}{x!(n-x)!} (1-p)^{(n-x)} p^x \\ &= \frac{5 \times 4 \times 3 \times 2}{(3 \times 2) \times 2} 0.7^{5-2} 0.3^2 = \frac{120}{12} 0.7^3 0.3^2 = 0.3087 \end{aligned}$$

- Vad är **väntevärde** och **varians** för antalet bilar?
 $E(X) = np = 5 \cdot 0.3 = 1.5$ och $V(X) = npq = 5 \cdot 0.3 \cdot 0.7 = 1.05$

Approximera binomialfördelning med normal

- Om $X \sim \text{Bin}(n, p)$ så gäller

$$E(X) = \mu = np \quad \text{och} \quad SD(X) = \sigma = \sqrt{npq}$$

- **Normalapproximation** av binomialfördelning

$$X \stackrel{\text{approx}}{\sim} N(np, \sqrt{npq})$$

- Approximationen är tillräckligt bra om

$$np \geq 10 \quad \text{och} \quad nq \geq 10$$

Båda dessa gäller om $npq \geq 10$ (dvs variansen ≥ 10).

- Man kan också göra en kontinuitetskorrektion som korrigerar för att vi approximerar en diskret fördelning (binomial) med en kontinuerlig (normal), see SDM-boken kapitel 15.5.

Normalapproximation av binomial – interaktivt

Binomialfördelningen

n : 

p : 

Kvantil: 

Visa
normalapproximation ☒

Om $X \sim \text{Binom}(10, 0.5)$ så gäller att


$$E(X) = np = 5.00$$

$$\text{Var}(X) = np(1 - p) = 2.50$$

Exakt: $P(X \leq 3) = 0.1719$

Normal approx: $P(X \leq 3) = 0.1030$

Normal approx med kontinuitetskorrektion: $P(X \leq 3) = 0.1714$



Några ord om problemlösning (t ex övningar)

- En sak som är bra i kursboken (“SDM”) är deras struktur för “step-by-step examples”.
- Lägg märke till det första steget *Think*, dvs en *tankefas* och *planeringsfas* för att lösa problemet.
- Vad som kan/bör ingå i denna fas är:
 - ▶ *Inför beteckningar* för de storheter/variabler du vill arbeta med.
 - ▶ Ställ upp relevanta *matematiska relationer* (ofta ekvationer) mellan storheter/variabler.
 - ▶ Skriv upp vilka *statistiska fördelningar* de slumpvariabler som ingår har.
 - ▶ Formulera den fråga du arbetar *matematiskt i termer av dina variabler*.
- När allt detta är klart kan du övergå till att använda den matematiska/statistiska verktygslåda du har tillgång till!

Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo VT 2026 och Tobias Rydén för HT2026.