Statistik och dataanalys I - F15

Statistiska institutionen

Jonas Bjermo

VT2026

Innehåll föreläsning 15

- **Likformig fördelning**
- **Normalfördelning**
- **Poissonfördelning**
- **Student-t**

Kontinuerliga slumpvariabler och täthetsfunktionen

- **Kontinuerlig slumpvariabel** antar alla värden, men $P(X = x) = 0$ för alla x!
- **Täthetsfunktion**: $f(x)$.
- Positiv $f(x) > 0$ för alla x.
- Täthetsfunktion ger **inte** sannolikheter. Möjligt att $f(x) > 1$.
- **Täthetsfunktionen** används för att **beräkna sannolikheter**: $P(a \leq X \leq b) =$ arean under $f(x)$ mellan a och b

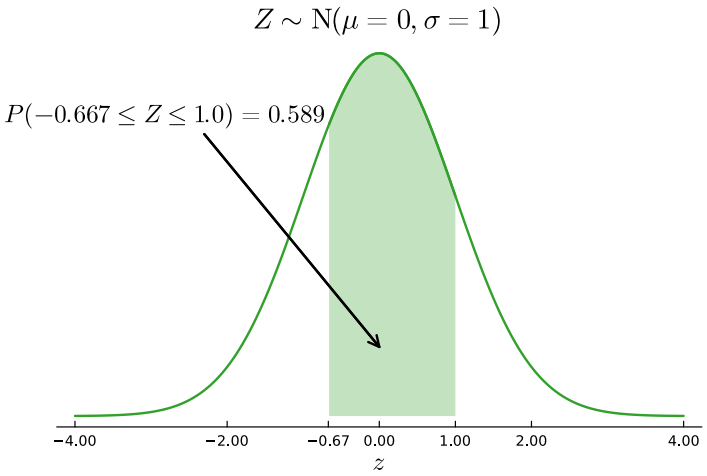

Likformig fördelning

- Varje värde är **lika** sannolikt.
- Kan definieras för **både** kontinueliga och diskreta slumpvariabler.
  - **Kontinuerliga**: Väntetid på buss som kommer exakt var 15:e minut?
  - Vilket nummer vinner på lotto?
- $X \sim U(a, b)$, läses som: X är likformigt fördelad inom intervallet a till b.
- **Täthetsfunktion**: $f(x) = \frac{1}{b-a}$ för alla $a \leq x \leq b$. Alla värden har samma sannolikhetstäthet!
- **Väntevärde och varians**: $E(X) = \frac{a+b}{2}$ och $Var(X) = \frac{(b-a)^2}{12}$

Likformig fördelning, exempel

- Min buss anländer alltid till hållplatsen varje 15 min. Jag går dit en slumpmässig tid, hur länge måste jag vänta?

- Bussen kan komma direkt (0 min väntetid), jag kan som mest få vänta 15 min, och allt där emellan är lika sannolikt.

- Hur länge förväntas jag få vänta och med vilken varians?

  $E(X) = \frac{b-a}{2} = \frac{15-0}{2} = 7.5$ minuter med varians
  $V(X) = \frac{(b-a)^2}{12} = \frac{(15-0)^2}{12} = \frac{15}{12} = \frac{5}{4}$ minuter.

- Sannolikheten att jag får vänta som mest 5 min? (CDF)
  $P(X \leq 5) = \frac{5-a}{b-a} = \frac{5}{15} = \frac{1}{3}$. Visa bild på tavlan!

Likformig fördelning

Likformig fördelning

a : 0

b : 1

Kvantil: 1

Om $X \sim \text{Uniform}(0, 1)$ så gäller att

$$E(X) = \frac{a+b}{2} = 0.500$$

$$Var(X) = \frac{(b-a)^2}{12} = 0.0833$$

$$P(X \leq 1) = 1.000$$

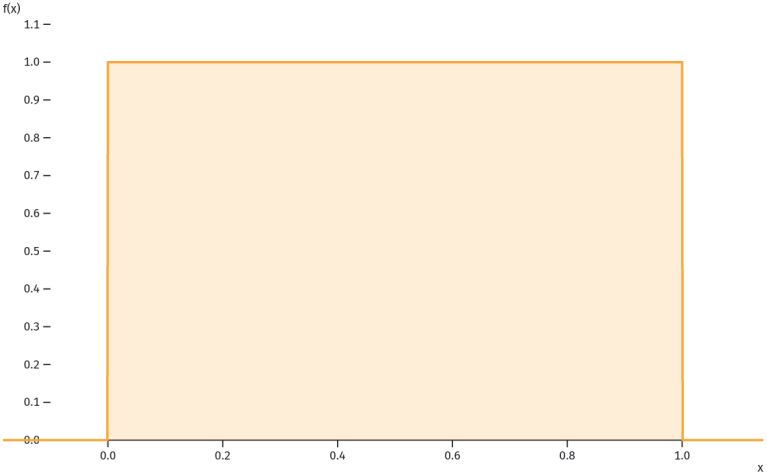

Mattias Villani Likformig fördelning

Observable

Normalfördelning

- $X \sim N(\mu, \sigma)$

$$E(X) = \mu$$

$$SD(X) = \sigma$$

- **68-95-99.7% regeln**

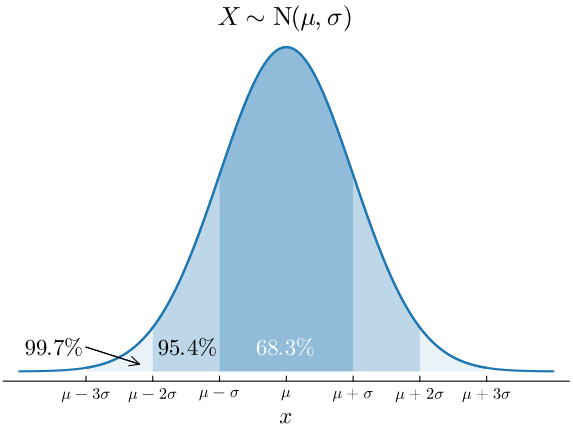

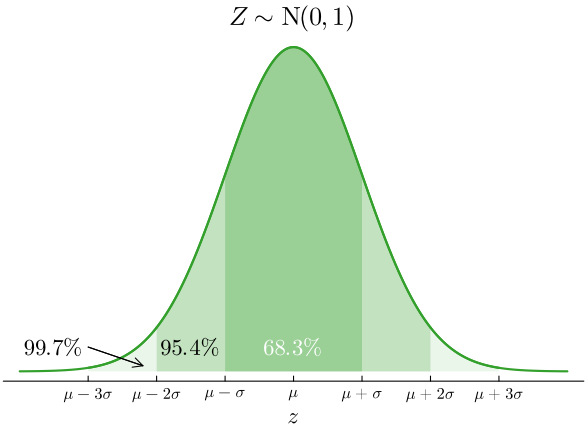

Normalfördelning - standardisering

- **Standardisering**

$$X \sim N(\mu, \sigma) \Rightarrow Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

- **Sannolikhet via standardisering** för $X \sim N(2, 3)$

$$P(X \leq 5) = P(X - 2 \leq 5 - 2) = P\left(\frac{X - 2}{3} \leq \frac{5 - 2}{3}\right) = P(Z \leq 1)$$

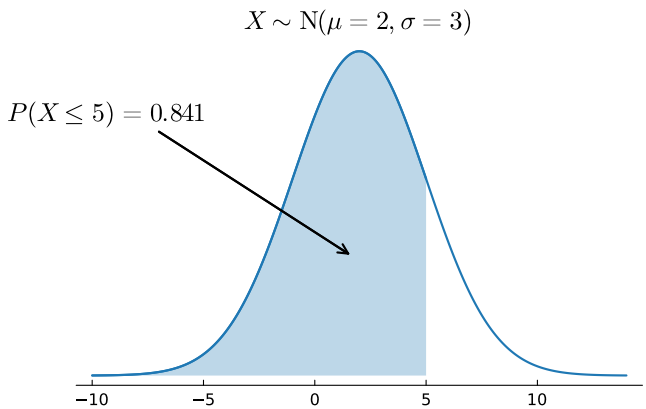

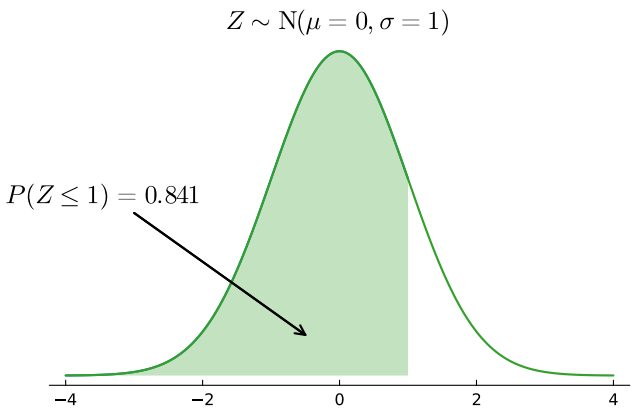

Normalfördelning - Z-tabell

Normalfördelning

Tabellen ger sannolikheten $\Phi(z) = P(Z \leq z)$ för olika z där Z är standardnormal, $Z \sim N(0,1)$.
Sannolikheter i den vänstra svansen fås genom symmetri: $P(Z \leq -z) = 1 - P(Z \leq z)$.

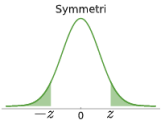

Andra decimalen i z

	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986

Normalfördelning - symmetri

- **Negativa** z-värden finns inte i Z-tabellen.
- Vi utnyttjar normalfördelningens **symmetri** för negativa z

$$P(Z \leq -2) = 1 - P(Z \leq 2)$$

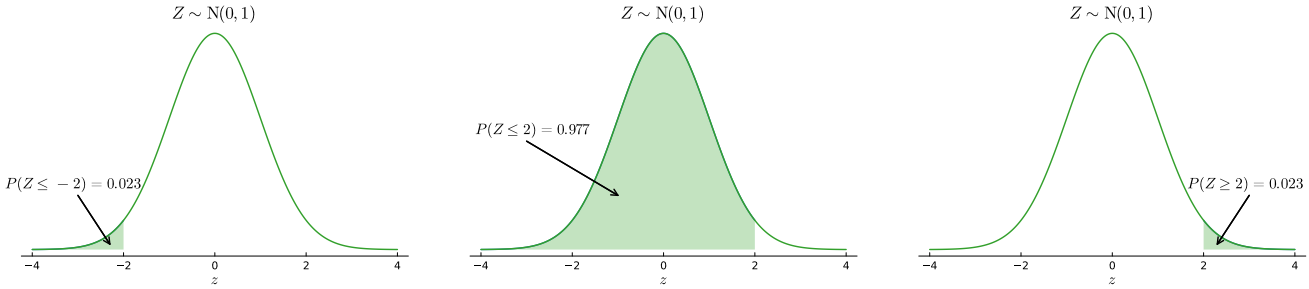

Normalfördelning - intervall via standardisering

- Sannolikhet via standardisering för$X \sim N(2, 3)$

$$P(0 \leq X \leq 5) = P\left(\frac{0-2}{3} \leq \frac{X-2}{3} \leq \frac{5-2}{3}\right) = P(-0.667 \leq Z \leq 1)$$
$$= P(Z \leq 1) - P(Z \leq -0.667)$$

och pga **symmetri**

$$P(Z \leq -0.667) = 1 - P(Z \leq 0.667)$$

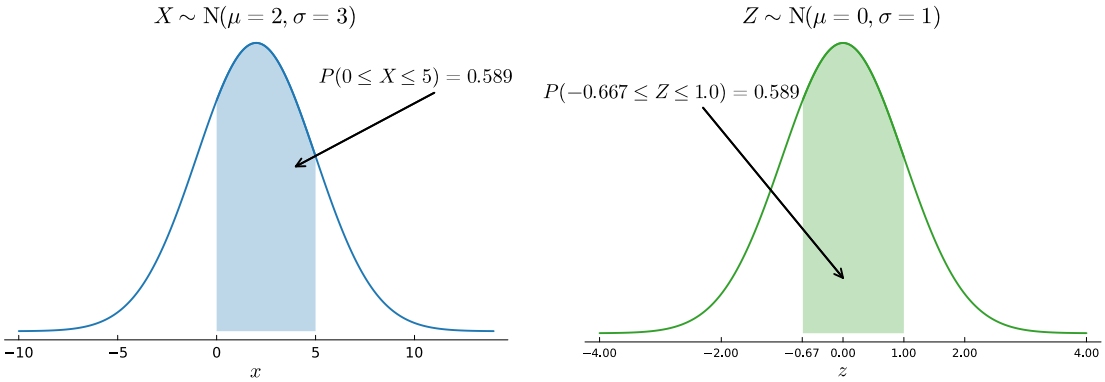

Normalfördelningen - interaktivt

Normalfördelningen

μ : 0

σ : 1

Kvantil: -1.96

Om $X \sim \mathrm{N}(0,1)$ så gäller att

$E(X) = \mu = 0.00$

$Var(X) = \sigma^2 = 1.00$

$P(X \leq -1.96) = 0.02500$

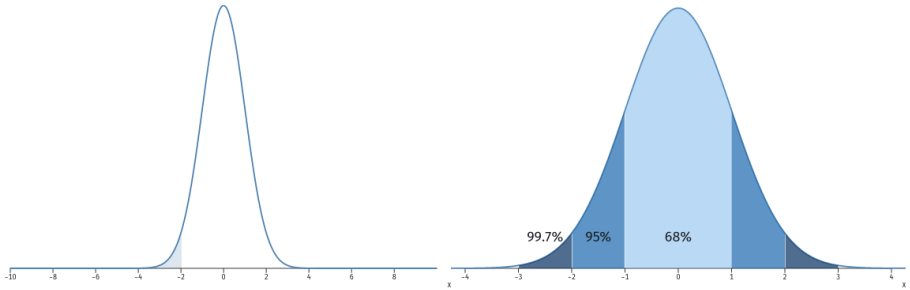

Mattias Villani Normalfördelningen

Observable

Normalfördelning - egenskaper

Linjärkombination av normalfördelad slumpvariabel

Om $X \sim \mathrm{N}(\mu, \sigma)$ och $Y = c + aX$ så gäller

$$Y \sim \mathrm{N}(c + a\mu,\ |a|\sigma)$$

Summa av **oberoende normalfördelade** slumpvariabler

Om $X \sim \mathrm{N}(\mu_X, \sigma_X)$ och $Y \sim \mathrm{N}(\mu_Y, \sigma_Y)$ är oberoende slumpvariabler så är även summan normalfördelad:

$$X + Y \sim \mathrm{N}(\mu_X + \mu_Y,\ \sqrt{\sigma_X^2 + \sigma_Y^2})$$

- **Fördelningarna** för linjärkombination och summa är **normal**!
- Summan är fortfarande normal om X **och** Y **är beroende**.

Poissonfördelning

- **Poissonfördelningen** är en fördelning för **räknedata** (antal):
  - antal buggar i en mjukvara
  - antal budgivare i en auktion
  - antal besök till läkaren.

- Om$X \sim \text{Pois}(\lambda)$ så

$$P(X = x) = \frac{e^{-\lambda}\lambda^x}{x!}, \qquad \text{för } x = 0, 1, 2, ...$$

- $e \approx 2.71$ är Eulers tal.

- Poisson har samma **väntevärde** och **varians**:

$$E(X) = \lambda$$

$$Var(X) = \lambda$$

Poissonfördelning - interaktivt

Poissonfördelningen

λ : 2

Quantile: 1

If $X \sim \text{Poisson}(2)$ then

$E(X) = \lambda = 2.00$

$Var(X) = \lambda = 2.00$

$P(X \leq 1) = 0.4060$

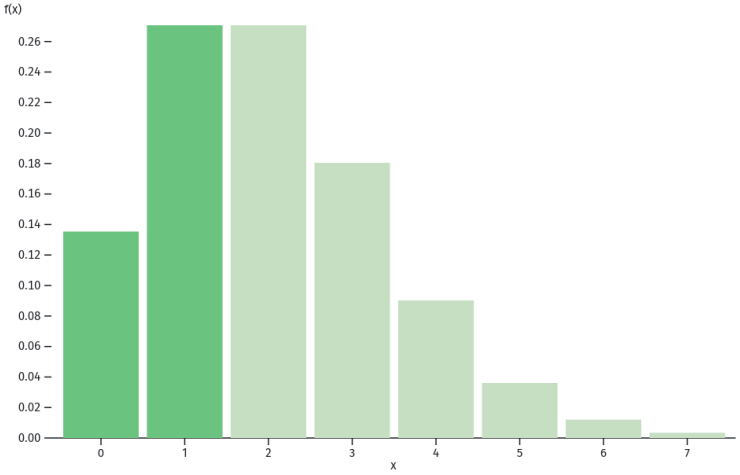

Mattias Villani Poisson distribution

Observable

Poissonfördelning för antal bud på eBay

- Data från 1000 **eBay-auktioner av samlarmynt**.
- `nBids` är **antalet budgivare** i en given auktion.
- Olika värdefulla och olika reservationspris (lägsta pris).
- Fokus här på de 550 observationer med lägst reservationspris.
- **Modell** för `nBids`: $X_1, \ldots, X_n \overset{\text{ober}}{\sim} \text{Pois}(\lambda)$.

[1]

	nBids	PowerSeller	VerifyID	Sealed	Minblem	MajBlem	LargNeg	LogBook	MinBidShare	Sold	low_res_price
1	2	0	0	0	0	0	0	-0.224	-0.209	True	low
2	6	1	0	0	0	0	0	0.607	-0.348	True	low
3	1	1	0	0	0	0	0	0.033	0.442	True	high
4	1	0	0	0	1	0	0	0.376	0.144	True	high
5	4	0	0	0	0	0	1	1.435	-0.41	True	low
6	2	0	0	0	0	0	0	-0.914	0.632	True	high
7	2	0	0	0	1	0	0	-0.248	0.295	True	high
8	2	0	0	0	0	0	0	-0.914	0.632	True	high
9	2	1	0	0	0	0	0	0.511	0.055	True	high
10	6	0	0	1	0	0	0	-0.362	0.025	True	high
11	0	1	0	0	0	0	0	-0.224	0.477	False	high

[1] Wegmann, B. och Villani, M. (2011). Bayesian Inference in Structural Second-Price Common Value Auctions, *Journal of Business and Economic Statistics*

Punktskattning av modellparametrar

- Modell för `nBids`: $X_1, \ldots, X_n \overset{\text{ober}}{\sim} \text{Pois}(\lambda)$.
- Hur väljer vi parametern λ? **Punktskattning**. **Estimat** $\hat{\lambda}$.
- **Momentmetoden**: Eftersom $\lambda = E(X)$ så är $\hat{\lambda} = \bar{x}$ rimligt.
- **Maximum likelihood**: välj det λ som maximerar sannolikheten för datamaterialet.
- Maximum likelihood-metoden funkar för alla modeller.

Maximum likelihood för Poisson - interaktivt

Maximum likelihood estimation - Poissonfördelning

Modell: $X_1, X_2, \ldots, X_n \overset{\text{ober}}{\sim} \text{Pois}(\lambda)$

λ : 2

Visa maximum likelihood anpassning ☐

Medelsannolikhet för observerad data med modellen Pois(λ = 2) är 0.01872

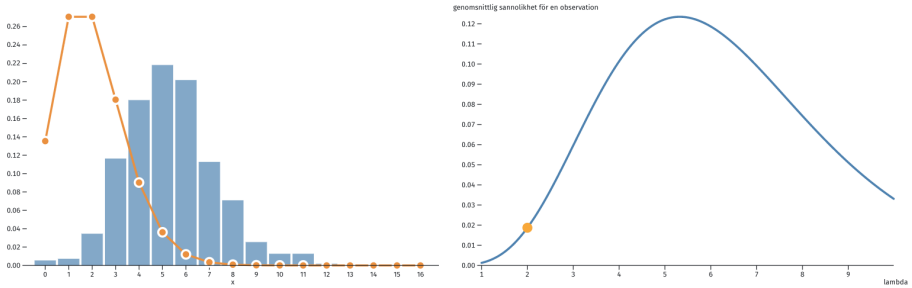

Mattias Villani Maximum likelihood - Poissonmodellen

Observable

Exponentialfördelning

- Beskriver **tiden tills- eller mellan** händelser. Kontinuelig variabel.
- Centralt koncept **minneslöshet**: slh för när en händelse ska inträffa är oberoende av hur länge man redan har väntat.
- **Exempel**: Väntetid på nästa telefonsamtal till en växel eller livslängd på en glödlampa.
- $X \sim Exp(\lambda)$, läses som: X är exponentialfördelad med rate-parameter (intensitet) λ .
- **Täthetsfunktion**: $f(x) = \lambda e^{-\lambda x}$, för $x \geq 0$. Tätheten avtar exponentiellt.
- **Väntevärde och varians**: $E(X) = \frac{1}{\lambda} och Var(X) = \frac{1}{\lambda^2}$

Exponentialfördelning, exempel

- **Exempel**: Ett servicecenter tar emot samtal med en genomsnittlig hastighet av 2 samtal per minut ($\lambda = 2$). Tiden mellan samtalen är exponentialfördelad. Hur länge dröjer det i genomsnitt till nästa samtal?

- Hur länge är förväntad väntetid?

  $E(X) = \frac{1}{\lambda} = \frac{1}{2}$ min, med varians $V(X) = \frac{1}{\lambda^2} = \frac{1}{4}$ min.

- Sannolikhet att nästa samtal kommer inom 30 sek? (CDF)

$$P(X \leq 0.5) = 1 - e^{-0.5\lambda} = 1 - e^{-1} \approx 0.63.$$

Student-t fördelning (standard)

- $X \sim t_\nu(0,1)$ är en **student-t fördelning** med ν frihetsgrader.
- Kontinuerliga symmetriska variabler över $(-\infty, \infty)$.
- Student-t har mer sannolikhet på **extrema** utfall.
- Student-t fördelning **alltmer lik normalfördelning** när ν ökar.

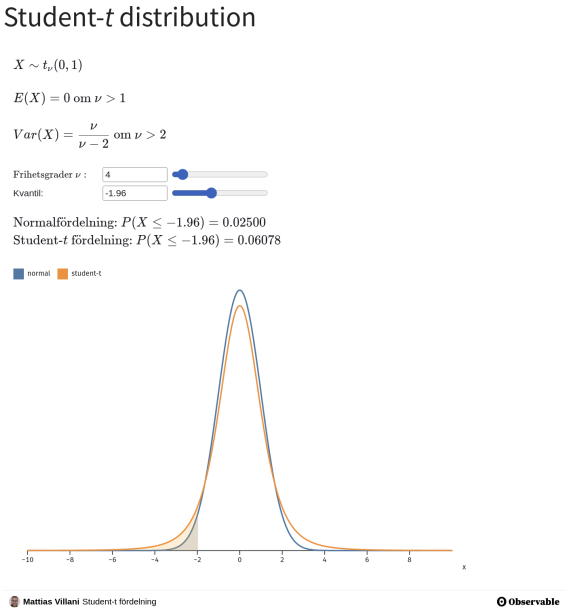

Varför student-t är viktig för inferens

- $X_1, X_2, \ldots, X_n$ är oberoende data från $N(\mu, \sigma)$.
- Stickprovmedelvärdet

$$\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n}$$

- **Inferens**: fördelningen för det **standardiserade medelvärdet**

$$\frac{\bar{X} - \mu}{SD(\bar{X})}$$

- Om variansen i populationen σ^2 **är känd** så är det standardiserade medelvärdet **normalfördela**.
- Om variansen i populationen σ^2 **är okänd**, och måste skattas med s^2, så är det standardiserade medelvärdet **student-t fördelad** med $\nu = n - 1$ frihetsgrader.

Student-t som modell för aktieavkastning

- Student-t fördelningen kommer visa sig viktig för inferens för väntevärdet μ i en normalpopulation. F17.
- Student-t är en bra modell för data med extremvärden.
- **Exempel**: Daglig avkastning Ericsson B aktie under hela år 2022.
- Finansiella data har ofta extremvärden. **Tunga svansar**.
- Maximum likelihood: $\mu = 0.094$, $\phi = 1.279$ och $\nu = 2.706$.

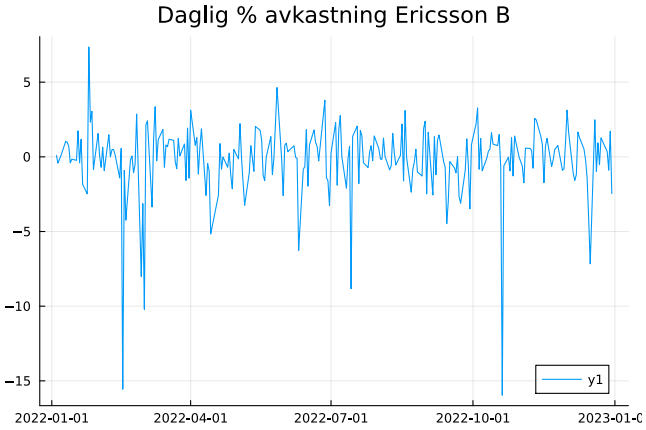

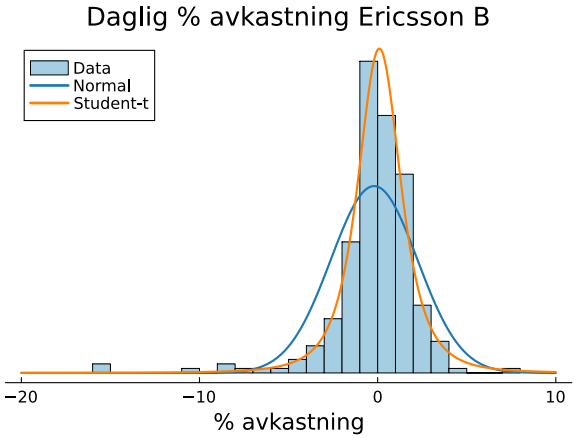

Allmän Student-t fördelning för datamodellering

Allmän Student-*t* distribution

$X \sim t_\nu(\mu, \phi^2)$

$E(X) = \mu$ om $\nu > 1$

$Var(X) = \dfrac{\nu}{\nu - 2}\phi^2$ om $\nu > 2$

Läge μ : 2

Skala ϕ : 1.5

Frihetsgrader ν : 4

Kvantil: 0

visa normalfördelning ☐

Student-t fördelning: $P(X \leq 0) = 0.1266$

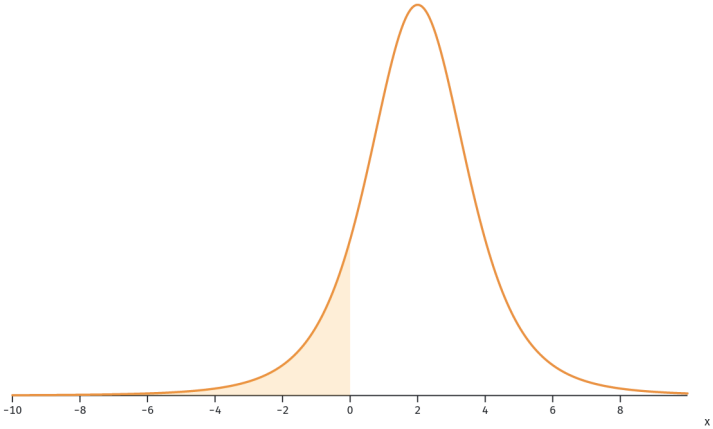

Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, och Jonas Bjermo VT 2026.