

Statistik och dataanalys I - F16

Statistiska institutionen


VT2026

Denna version: 2026-10-04


Innehåll föreläsning 16

- **Sannolikhetsmodeller** och verkligheten
- **Samplingfördelningen**
- **Samplingfördelningen** för en **andel**


Population och stickprov - ändliga populationer




Modeller som en förenkling av verkligheten




Sannolikhetsmodeller och inferens




Sannolikhetsmodeller möter verkligheten - prediktion



Modellering är en iterativ process



Slutmålet är ofta beslutsfattande i en osäker värld




Statistika, estimator och estimat

- **Statistika** - kvantitet som beräknas från ett stickprov.
- Det kan vara en *andel*, t ex andelen som röstar på socialdemokraterna i en valundersökning.
- Det kan vara ett *medelvärde*, t ex medelvärdet av inkomster för personer i ett stickprov.
- Det kan vara en *(stickprovs)standardavvikelse*, t ex standardavvikelsen för inkomster för personer i ett stickprov.
- Vi använder en statistika för att **skatta** en *populationsparameter*.
 - ▶ En *populationsandel* p skattas med en stickprovsandel
 - ▶ Ett *(populations)väntevärde* μ skattas med ett (stickprovs)medelvärde
 - ▶ En *populationsstandardavvikelse* σ skattas med en stickprovsstandardavvikelse.

Väljarundersökningar

- Vilket parti skulle du rösta på om det vore val idag?
- SVT/Novus. **Stickprov** med $n = 3539$ personer.



- Kontaktade via telefon eller sms. Representativt? Bortfall?
- **Population**: röstberättigade i Sverige.
- **Populationsparameter**: andelen S-röstare i populationen p .
- **Statistika** för att skatta p : andelen S-röstare i stickprovet.
- Den skattning av populationsparametern som beräknas för ett stickprov kallas ett **estimat**. I SVT/Novus undersökning:

$$\hat{p} = \frac{1313}{3539} \approx 0.371 \text{ dvs } 37.1\%$$

Samplingfördelningen

- Men, $\hat{p} = 0.371$ är bara ett estimat, med osäkerhet, från ett slumpmässigt valt stickprov.
- Om vi hade frågat 3539 **andra personer** hade vi säkerligen fått ett annat estimat.
- Hur hanterar vi det här? Vi vill veta hur den slumpmässiga variationen för estimatet ser ut, när i drar ett stickprov om $n = 3539$ personer slumpmässigt. Detta kallas *samplingfördelningen*.
- Vi löser detta genom att att *modellera* antalet S-röstare i stickprovet. Låt X vara detta antal, betraktat som en slumpvariabel. Parametern p är populationsandelen S-röstare.
- Vi kan nu skriva $\hat{p} = X/n$, dvs vi *betraktar skattningen som en slumpvariabel*. Vi använder termen **estimator** för detta.
- Vi kan då säga att *samplingfördelningen är fördelningen för en estimator*.

Stora talens lag - andel

Stora talens lag - normalapproximation av andel

Normalapproximation av samplingfördelningen för en andel


n 

p 

Stickprovet $n = 30$ är större än 30. ✓

Antal förväntade lyckade $np = 15.0$ är större än 10. ✓

Antal förväntade misslyckade $nq = 15.0$ är större än 10. ✓




Samplingfördelningen för en andel

- Vi vill använda samplingfördelningen för $\hat{p}$ för att svara på t ex:
 - ▶ Vad är precisionen (med något mått) för estimatoren $\hat{p}$?
 - ▶ Kan vi konstruera ett *intervall* som vi tror innehåller det sanna, okända värdet p ?
 - ▶ Är en ändring i estimatet för S-andelen relativt månaden före *statistiskt säkerställd*?
- Notera här att parametern p är ett *okänt men fixt tal*, medan $\hat{p}$ är en *slumpvariabel*.
- Antag att $X \sim \text{Bin}(n, p)$ är en rimlig modell för X .
(Vi har diskuterat tidigare när detta är fallet.)
- Fördelningen för $\hat{p} = X/n$ är inte någon av dem vi tagit upp, men vi kan säga en del om $\hat{p}$ ändå!
- Notera att beteckningen $\hat{p}$ används *både* för slumpvariabeln $\hat{p}$ och för ett utfall av denna (till skillnad från t ex X och x).
Sammanhanget avgör vilket som avses.

Samplingfördelningen för en andel (forts.)

- Först: $E(\hat{p}) = E(X/n) = (1/n)E(X) = (1/n)np = p$.
- Vi säger att $\hat{p}$ är **väntevärdesrikting** för populationsandelen p ; $\hat{p}$ är *korrekt i genomsnitt*, sett över alla möjliga stickprov.
- Estimatorns **bias** är $\text{Bias}(\hat{p}) = E(\hat{p}) - p = 0$.
- Vidare $SD(\hat{p}) = SD(X/n) = (1/n)\sqrt{npq} = \sqrt{pq/n}$.
- Precisionen i $\hat{p}$, mätt som standardavvikelse, blir bättre (SD mindre) när n växer. Att SD avtar som $1/\sqrt{n}$ är typiskt för en estimator.
- **Stora talens lag**: $\hat{p}$ kommer att vara nära p när n växer. Formellt: $\hat{p}$ *konvergerar* mot p när n växer (går mot ∞).

Väntevärdesriktighet, bias och varians




Normalfördelningen – en recap

- För $Y \sim N(\mu, \sigma)$ har vi 68-95-99.7 regeln:
 - ▶ $P(Y \text{ är högst en standardavvikelse från } \mu) = 0.683$
 - ▶ $P(Y \text{ är högst två standardavvikelser från } \mu) = 0.954$
 - ▶ $P(Y \text{ är högst tre standardavvikelser från } \mu) = 0.997$
- Vanligt att vi vill ha “jämnare” sannolikheter:
 - ▶ $P(Y \text{ är högst 1.645 standardavvikelser från } \mu) = 0.90$
 - ▶ $P(Y \text{ är högst 1.96 standardavvikelser från } \mu) = 0.95$
 - ▶ $P(Y \text{ är högst 2.576 standardavvikelser från } \mu) = 0.99$
- Hur kommer vi fram till detta? Nästa sida!

Kritiskt värde för 95%-igt konfidensintervall

- Intervall med sannolikhet 0.95:
 - ▶ Sannolikhetsmassa **utanför** intervallet: $\alpha = 0.05$
 - ▶ Sannolikhetsmassa i **vardera svans**: $\alpha/2 = 0.025$
 - ▶ $z_{\alpha/2} = z_{0.025} = 1.96$
 - ▶ 2.5% av sannolikhetsmassan till **höger** om $z_{0.025}$.
 - ▶ 97.5% av sannolikhetsmassan till **vänster** om $z_{0.025}$.
 - ▶ $z_{0.025}$ från Z-tabell, det z där $P(Z \leq z) = 1 - 0.025 = 0.975$

95%-igt intervall: $z_{0.025} = 1.96$



95%-igt konfidensintervall för p

- Vi vet att $X \stackrel{approx}{\sim} N(np, \sqrt{npq})$ (vi antar $npq \geq 10$).
- En linjärtransformation av en normalfördelad slumpvariabel är också normalfördelad. Det medför att

$$X/n \stackrel{approx}{\sim} N(p, \sqrt{pq/n}).$$

- Dvs $\hat{p} \stackrel{approx}{\sim} N(p, \sqrt{pq/n})$.
- Idé: För en slumpvariabel från $N(\mu, \sigma)$ gäller att utfallet faller i intervallet $\mu \pm 1.96\sigma$ med 95% sannolikhet.

I vårt fall: $\hat{p}$ faller i intervallet $p \pm 1.96\sqrt{pq/n}$ med ca 95% sannolikhet.

- Kan vi vända på resonemanget och säga att intervallet $\hat{p} \pm 1.96\sqrt{pq/n}$ innehåller p med ca 95% sannolikhet?

Konfidensintervall för p (forts.)

- Ja, det fungerar – vi kan vända på resonemanget! Men vi har ett problem, då $\sqrt{pq/n}$ innehåller den okända parametern p .
- Vi ersätter p med $\hat{p}$ i detta uttryck, dvs ersätter $SD(\hat{p}) = \sqrt{pq/n}$ med **standardfelet** $SE(\hat{p}) = \sqrt{\hat{p}\hat{q}/n}$ (“SE” för *standard error*).
- *Standardfelet* för en estimator är en uppskattning av *standardavvikelsen* för samma estimator. Uttrycket för standardfelet skall inte innehålla några okända parametrar och alltså gå att beräkna från stickprovet.
- Ett **konfidensintervall** för p med 95% konfidensgrad blir då $\hat{p} \pm 1.96 SE(\hat{p})$, dvs $\hat{p} \pm 1.96\sqrt{\hat{p}\hat{q}/n}$, eller

$$\left(\hat{p} - 1.96\sqrt{\frac{\hat{p}\hat{q}}{n}}, \hat{p} + 1.96\sqrt{\frac{\hat{p}\hat{q}}{n}} \right).$$

Exempel – röstandel för S

- $\hat{p} = 0.371$, men $\hat{p}$ varierar från stickprov till stickprov.
- Är antagandet $\text{Bin}(n, p)$ rimligt? Ja, då vi har ett slumpmässigt urval och urvalet definitivt är högst 10% av populationen.
- Är approximationen $\hat{p} \sim N(p, \sqrt{pq/n})$ rimlig? Vi känner inte p (eller q), men $n\hat{p}\hat{q} \approx 826 \geq 10$, så “ja” även här. (Vi kan också kontrollera $n\hat{p} \geq 10$ och $n\hat{q} \geq 10$.)
- Standardfelet för $\hat{p}$ är

$$\sqrt{\hat{p}\hat{q}/n} = \sqrt{0.371(1 - 0.371)/3539} \approx 0.00812$$

- .
- Ett approximativt 95%-igt konfidensintervall blir $0.371 \pm 1.96 \times 0.00812 = [0.355, 0.387]$.

95%-igt konfidensintervall för en andel

- Normalapproximation $\hat{p} \sim N(p, \sqrt{pq/n})$.

Approximativt 95%-igt konfidensintervall för andel p


$$\hat{p} \pm z_{0.025} \cdot SE(\hat{p}) \text{ där } SE(\hat{p}) = \sqrt{\frac{\hat{p}\hat{q}}{n}} \text{ och } z_{0.025} = 1.96$$

- Intervall från **givet stickprov** antingen täcker eller missar p .
- Ett 95%-igt konfidensintervall kommer innehålla populationsvärdet p i **95% av alla möjliga stickprov**.
- “Den sanna andelen är i intervallet **med 95% säkerhet**”.
- Men säkra blir vi aldrig.

Kritisk värde för 80%-igt konfidensintervall


- Intervall med sannolikhet 0.8:
 - ▶ $\alpha = 0.2$
 - ▶ $z_{\alpha/2} = z_{0.1} = 1.282$
 - ▶ “värdet som har 10% av sannolikhetsmassan till höger om sig i standard normalfördelning”

80%-igt intervall: $z_{0.1} = 1.282$



Kritisk värde - konfidensintervall $1 - \alpha$ sannolikhet

- **Kritiskt värde** för ett intervall med sannolikhet $1 - \alpha$:
 - ▶ Sannolikhetsmassa **utanför** intervallet: α
 - ▶ Sannolikhetsmassa i **vardera svans**: $\alpha/2$
 - ▶ $z_{\alpha/2}$ “har $\alpha/2$ av sannolikhetsmassan till höger om sig i standard normalfördelning”




Konfidsensintervall för en andel - interaktivt

Konfidsensintervall för en andel - normalapproximation

Populationsandel, p 
Konfidensnivå 
Stickprovstorlek, n 

 antal stickprov = 193

Av totalt 193 stickprov innehöll 177 st (**91.710%**) av de 90%-iga konfidsensintervallen den sanna populationsandelen $p = 0.5$.



Konfidensintervall för en andel

- Normalapproximation $\hat{p} \sim N(p, \sqrt{pq/n})$

Approximativt $(1 - \alpha)\%$ -igt konfidensintervall för andel p

$$\hat{p} \pm z_{\alpha/2} \cdot SE(\hat{p}) \quad \text{med } SE(\hat{p}) = \sqrt{\hat{p}\hat{q}/n}$$

- **Felmarginal** (eng. margin of error, ME): $z_{\alpha/2} \cdot SE(\hat{p})$
- Konfidensintervall: Estimat $\pm$ Felmarginal
- Gränserna i konfindensintervall avrundas ofta *utåt*.
- Trade-off: **högre konfidensnivå** $\implies$ **större felmarginal**.
- SDM-boken: z^* istället för $z_{\alpha/2}$.
- SDM-boken avrundar också ofta $z_{0.025} = 1.96$ till $z^* = 2$.

Slutligen: hur kunde vi “vända på resonemanget”?

- Givet approximationen $\hat{p} \sim N(p, SD(\hat{p}))$ har händelsen

$$A = \{p - z_{\alpha/2}SD(\hat{p}) \leq \hat{p} \leq p + z_{\alpha/2}SD(\hat{p})\}$$

sannolikheten $1 - \alpha$.

- Olikheten $p - z_{\alpha/2}SD(\hat{p}) \leq \hat{p}$ är ekvivalent med $p \leq \hat{p} + z_{\alpha/2}SD(\hat{p})$, och $\hat{p} \leq p + z_{\alpha/2}SD(\hat{p})$ är ekvivalent med $\hat{p} - z_{\alpha/2}SD(\hat{p}) \leq p$.
- Alltså kan händelsen A också uttryckas

$$A = \{\hat{p} - z_{\alpha/2}SD(\hat{p}) \leq p \leq \hat{p} + z_{\alpha/2}SD(\hat{p})\};$$

sannolikheten är fortfarande $1 - \alpha$ (samma händelse!).

- Approximera $SD(\hat{p}) = \sqrt{pq/n}$ med $SE(\hat{p}) = \sqrt{\hat{p}\hat{q}/n}$; händelsen

$$B = \{\hat{p} - z_{\alpha/2}SE(\hat{p}) \leq p \leq \hat{p} + z_{\alpha/2}SE(\hat{p})\},$$

har *approximativt* sannolikheten $1 - \alpha$. Intervallet som ges av B är konfidensintervallet med approximativ konfidensgrad $1 - \alpha$.

- Två approximationer görs: dels $\hat{p} \sim N(p, SD(\hat{p}))$ och dels när $SD(\hat{p})$ ersätts med $SE(\hat{p})$.

Konfidensintervall för andel i R

- Socialdemokraternas väljarandel

```
> prop.test(x = 1313, n = 3539)
```

1-sample proportions test with continuity correction

```
data: 1313 out of 3539
X-squared = 235.02, df = 1, p-value < 2.2e-16
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.3551012 0.3871985
sample estimates:
              p
0.3710088
```

- Överlevande Titanic

```
> library(sda123) # for titanic data with n = 886 passengers
> prop.test(~survived, data = titanic)
```

1-sample proportions test with continuity correction

```
data: titanic$survived [with success = 1]
X-squared = 46.002, df = 1, p-value = 1.181e-11
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.3535443 0.4185986
sample estimates:
              p
0.3855693
```

Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo VT 2026 och Tobias Rydén HT 2026.