Stockholms universitet

Statistik och dataanalys I - F17

Statistiska institutionen

HT2026

Denna version: 2026-10-08

Innehåll föreläsning 17

- **Samplingfördelningen för ett medelvärde**
- **Konfidensintervall för ett väntevärde**
- **Stora talens lag och Centrala gränsvärdessatsen**

Samplingfördelning för $\bar{X}$ – normalmodellen

- **Modell för populationen**: $X_1, X_2, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma)$
- **iid** betyder *independent and identically distributed*, dvs *oberoende och likafördelade*.
- Vi **skattar** populationens väntevärde $\mu = E(X)$ med

$$\bar{X} = \frac{1}{n} \sum_{i=1}^{n} X_i.$$

Samplingfördelning $\bar{X}$

Om $X_1, X_2, \ldots, X_n \overset{iid}{\sim} N(\mu, \sigma)$ så $\bar{X} \sim N(\mu, \sigma/\sqrt{n})$

- Vi måste visa tre saker:
  - $E(\bar{X}) = \mu$
  - $SD(\bar{X}) = \sigma/\sqrt{n}$
  - $\bar{X}$ är normalfördelad

Samplingfördelning för $\bar{X}$ – normalmodellen

- Mha räknereglerna för skalning och summor för väntevärden, samt modellantagandet $E(X_i) = \mu$ för alla i, får vi

$$\begin{aligned} E(\bar{X}) &= E(\tfrac{1}{n}\textstyle\sum_{i=1}^{n} X_i) = \tfrac{1}{n} E(\sum_{i=1}^{n} X_i) = \tfrac{1}{n}\sum_{i=1}^{n} E(X_i) \\ &= \tfrac{1}{n}\textstyle\sum_{i=1}^{n} \mu = \tfrac{1}{n}(n\mu) = \mu \end{aligned}$$

  Alltså är $\bar{X}$ en **väntevärdesriktig** estimator av μ.

- Pss får vi för variansen (kom ihåg att X_i är oberoende)

$$\begin{aligned} Var(\bar{X}) &= Var(\tfrac{1}{n}\textstyle\sum_{i=1}^{n} X_i) = \tfrac{1}{n^2} Var(\sum_{i=1}^{n} X_i) \\ &= \tfrac{1}{n^2}\textstyle\sum_{i=1}^{n} Var(X_i) = \tfrac{1}{n^2}\sum_{i=1}^{n} \sigma^2 = \tfrac{1}{n^2}(n\sigma^2) = \sigma^2/n \end{aligned}$$

- Slutligen: $\sum_{i=1}^{n} X_i$ är en summa av oberende normalfördelade slumpvariabler, och därmed normalfördelad. Sedan är $\bar{X}$ en skalning av $\sum_{i=1}^{n} X_i$, och därmed normalfördelad.

KI väntevärde – normalpopulation med känd varians

- Då $Var(\bar{X}) = \sigma^2/n$ har vi alltså $SD(\bar{X}) = \sigma/\sqrt{n}$.
- Från samplingfördelningen $\bar{X} \sim N(\mu, \sigma/\sqrt{n})$ kan vi skapa ett konfidensintervall:

Antag $X_1, X_2, \ldots, X_n \overset{iid}{\sim} N(\mu, \sigma)$ med σ känd

Ett $(1-\alpha)$%-igt konfidensintervall för väntevärdet μ är då

$$\bar{x} \pm z_{\alpha/2} \cdot SD(\bar{x}) \quad \text{med} \quad SD(\bar{x}) = \sigma/\sqrt{n}$$

KI väntevärde – normalpopulation med känd varians

- Varför är konfidensintervallet korrekt? Då $\bar{X} \sim N(\mu, \sigma/\sqrt{n})$ gäller

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1),$$

och därmed

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha.$$

- Multiplicera upp $\sigma/\sqrt{n}$ för att skriva händelsen i $P(\cdot)$ som $-z_{\alpha/2}\sigma/\sqrt{n} \leq \bar{X} - \mu \leq z_{\alpha/2}\sigma/\sqrt{n}$, och flytta sedan runt i olikheterna för att få $\bar{X} - z_{\alpha/2}\sigma/\sqrt{n} \leq \mu \leq \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}$. Men detta är bara olika uttryck för samma händelse, så att

$$P(\bar{X} - z_{\alpha/2}\sigma/\sqrt{n} \leq \mu \leq \bar{X} + z_{\alpha/2}\sigma/\sqrt{n}) = 1 - \alpha.$$

- Alltså är $\bar{X} \pm z_{\alpha/2}\sigma/\sqrt{n}$ ett KI för μ med täckningsgrad $1 - \alpha$.
- Poängen med standardiseringen ovan är att fördelningen för Z *inte beror på okända parametrar*, och därmed vet vi kvantilerna för Z.

Normalpopulation med okänd varians

- Variansen σ^2 i populationen är oftast **okänd**.
- Vi kan **skatta** σ^2 med **stickprovsvariansen**

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

- Varför $n-1$? För att S^2 är **väntevärdesriktig** för σ^2;

$$E(S^2) = E\left(\frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2\right) = \sigma^2.$$

- **Om** μ är **känd** kan vi skatta σ^2 väntevärdesriktigt med $\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{n}$
- "Förlorar en frihetsgrad" när vi skattar μ med $\bar{x}$.
- SDM-boken (s. 538): stickprovet kommer ligga närmare $\bar{x}$ än μ i genomsnitt. Avvikelserna $x_i - \bar{x}$ blir för små i genomsnitt.

Okänd varians $\Longrightarrow$ Student-t fördelning

- Om σ^2 är **känd** har vi $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0,1)$.
- Om σ^2 är **okänd** så **skattas** σ^2 med S^2 och Z ersätts med

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1},$$

  dvs T har en Student-t fördelning med $n-1$ frihetsgrader (df).
- Alltså: när standardavvikelsen i populationen måste skattas får den standardiserade $\bar{X}$ **tyngre svansar**.
- **Standardavvikelsen** för $\bar{X}$ är $SD(\bar{X}) = \sigma/\sqrt{n}$; kan användas när σ är känd.
- **Standardfelet** för $\bar{X}$ är $SE(\bar{X}) = s/\sqrt{n}$; kan användas när σ är okänd och måste skattas.
- För stora n är fördelningen t_{n-1} väsentligen lika med $N(0,1)$.
- Att fördelningen för T kan beräknas beror på att $\bar{X}$ och S^2 är *oberoende* slumpvariabler (vid normalfördelade data!).

Student-t fördelning

Student-*t* distribution

$X \sim t_\nu(0,1)$

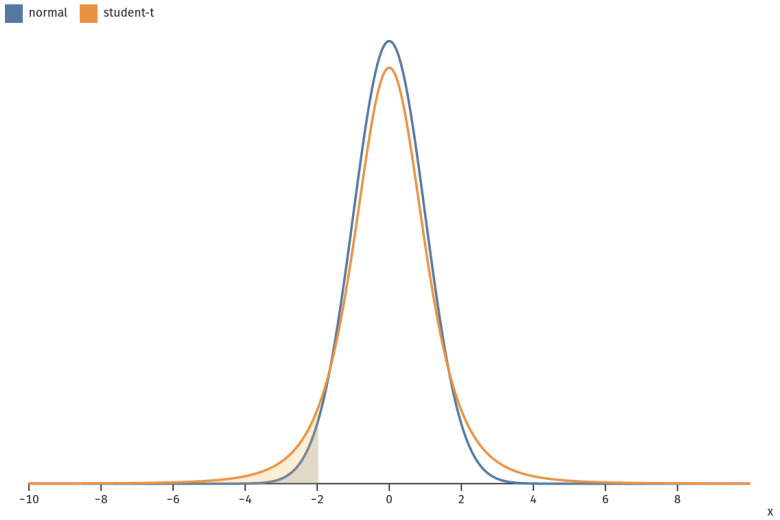
$E(X) = 0$ om $\nu > 1$

$Var(X) = \dfrac{\nu}{\nu - 2}$ om $\nu > 2$

Frihetsgrader ν : 4

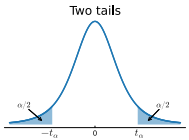
Kvantil: -1.96

Normalfördelning: $P(X \leq -1.96) = 0.02500$
Student-t fördelning: $P(X \leq -1.96) = 0.06078$



K.I. väntevärde – normalpopulation, okänd varians

- Notera att fördelningen för T inte innehåller några okända parametrar!
- Kritiska värden för t-fördelningen med $n-1$ frihetsgrader betecknas $t_{\alpha/2,n-1}$, dvs $P(T > t_{\alpha/2,n-1}) = \alpha/2$.



- Analogt med när σ är känt har vi alltså

$$\begin{aligned} 1-\alpha &= P(-t_{\alpha/2,n-1} \leq T \leq t_{\alpha/2,n-1}) \\ &= P\left(-t_{\alpha/2,n-1} \leq \frac{\bar{X}-\mu}{S/\sqrt{n}} \leq t_{\alpha/2,n-1}\right), \end{aligned}$$

- Rulla sedan tillbaka standardiseringen som tidigare för att få konfidensintervallet $\bar{X} \pm t_{\alpha/2,n-1} s/\sqrt{n}$.

K.I. väntevärde – normalpopulation, okänd varians

Antag $X_1, X_2, \ldots, X_n \overset{iid}{\sim} N(\mu, \sigma)$ med σ okänd.

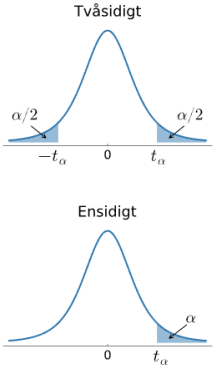
Ett $(1-\alpha)\%$-igt konfidensintervall för väntevärdet μ är då

$$\bar{x} \pm t_{\alpha/2,n-1} \cdot SE(\bar{x}) \quad \text{med} \quad SE(\bar{x}) = s/\sqrt{n},$$

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Student-t tabell

Student-t fördelning



Konfidensnivå:	80%	90%	95%	98%	99%
Tvåsidig sannolikhet:	0.200	0.100	0.050	0.020	0.010
Ensidig sannolikhet:	0.100	0.050	0.025	0.010	0.005
df					
1	3.078	6.314	12.706	31.821	63.657
2	1.886	2.920	4.303	6.965	9.925
3	1.638	2.353	3.182	4.541	5.841
4	1.533	2.132	2.776	3.747	4.604
5	1.476	2.015	2.571	3.365	4.032
6	1.440	1.943	2.447	3.143	3.707
7	1.415	1.895	2.365	2.998	3.499
8	1.397	1.860	2.306	2.896	3.355
9	1.383	1.833	2.262	2.821	3.250
10	1.372	1.812	2.228	2.764	3.169
11	1.363	1.796	2.201	2.718	3.106
12	1.356	1.782	2.179	2.681	3.055
13	1.350	1.771	2.160	2.650	3.012
14	1.345	1.761	2.145	2.624	2.977
15	1.341	1.753	2.131	2.602	2.947
16	1.337	1.746	2.120	2.583	2.921
17	1.333	1.740	2.110	2.567	2.898
18	1.330	1.734	2.101	2.552	2.878
19	1.328	1.729	2.093	2.539	2.861
20	1.325	1.725	2.086	2.528	2.845
21	1.323	1.721	2.080	2.518	2.831
22	1.321	1.717	2.074	2.508	2.819
23	1.319	1.714	2.069	2.500	2.807
24	1.318	1.711	2.064	2.492	2.797
25	1.316	1.708	2.060	2.485	2.787
26	1.315	1.706	2.056	2.479	2.779
27	1.314	1.703	2.052	2.473	2.771

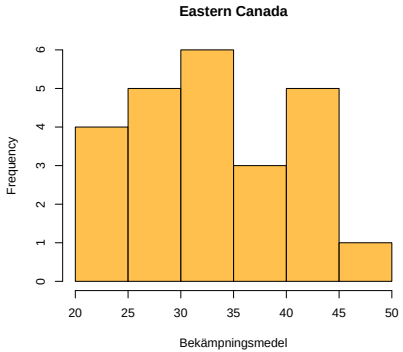
Bekämpningsmedel i odlad lax

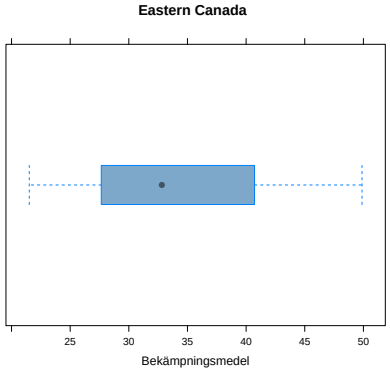
- Datamaterial med gifter i 153 laxar vid 8 olika platser.
- Bekämpningsmedel i Eastern Canada med $n = 24$ laxar:

  $x = c(25.739, 24.799, 27.563, 21.511, 23.821, 23.311, 49.883, 42.352, 44.598,$

  $31.353, 33.837, 33.915, 41.668, 42.383, 43.638, 39.768, 35.256, 36.270, 29.630,$

  $31.266, 32.577, 33.056, 29.789, 27.737)$
- **Modell**: $X_1, X_2, \ldots, X_n \overset{iid}{\sim} N(\mu, \sigma)$ och σ okänd.
- **Normalfördelad population**? Titta på stickprovet:





- Svårt se med få observationer. Histogram ok. Inga outliers.

Bekämpningsmedel i odlad lax

- **95%-igt konfidensintervall** för μ : $(30.332, 36.811)$

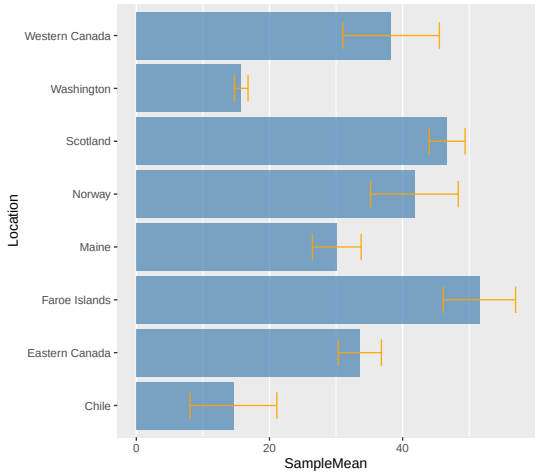
$$\bar{x} \pm t_{0.025,n-1}\frac{s}{\sqrt{n}} = 33.572 \pm t_{0.025,23}\frac{7.671}{\sqrt{24}} = 33.572 \pm 2.069\frac{7.671}{\sqrt{24}}$$

- $t_{0.025,23} = 2.069$ från tabell, eller R: `qt(0.975, df = 23)`.
- **Standardavvikelsen** s beräknas i R som `sd(x)`, eller för hand:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Bekämpningsmedel i odlad lax

- **68%-igt konfidensintervall** för μ : $(31.980, 35.163)$
- **95%-igt konfidensintervall** för μ : $(30.332, 36.811)$
- **99%-igt konfidensintervall** för μ : $(29.176, 37.968)$
- Högre konfidens $\Longrightarrow$ bredare intervall.
- 95%-iga konfidensintervall alla orter:



- Se R-koden confidence_intervals_salmon.R på kurswebbsidan.

Konfidensintervall för väntevärde i R

```
> t.test(pesticides_EC, conf.level = 0.95)

        One Sample t-test

data:  pesticides_EC
t = 21.439, df = 23, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 30.33231 36.81103
sample estimates:
mean of x
 33.57167
```

Skatta väntevärde - godtycklig population

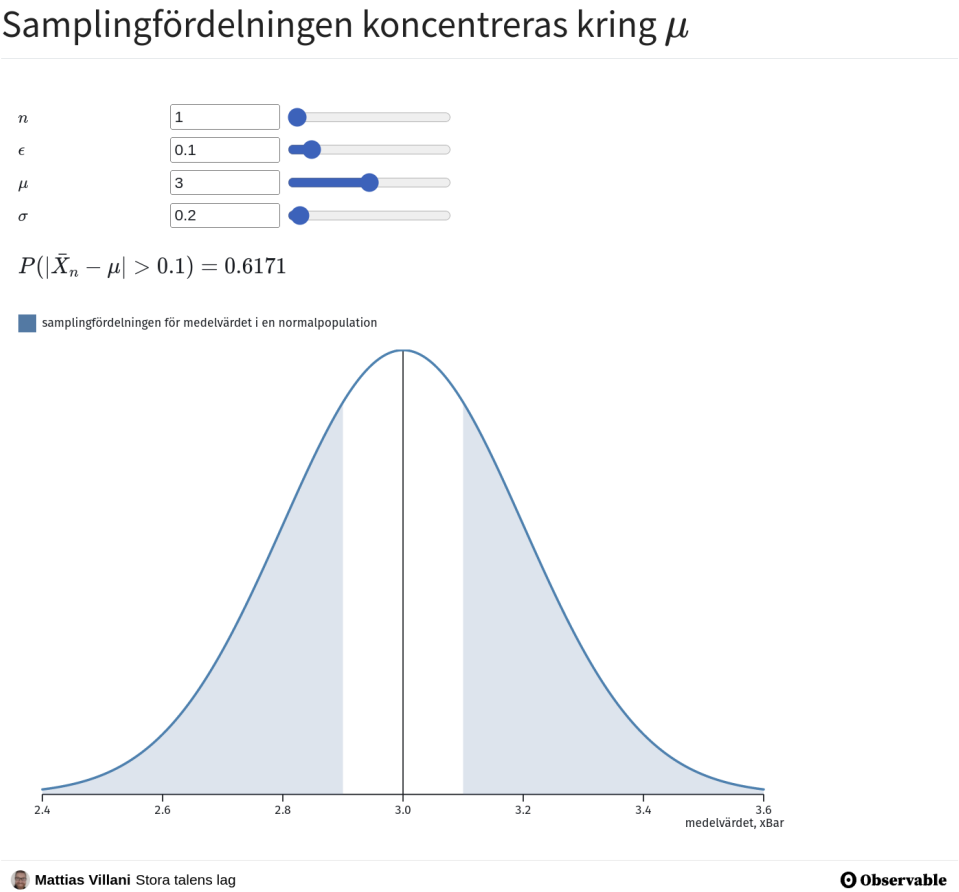
- Vi antar nu att $X_1, X_2, \ldots, X_n$ är oberoende med väntevärde μ och **okänd** varians σ^2
- I övrigt är fördelningen för X_i **godtycklig** (och okänd).
- Vi skattar μ med $\bar{X}$. Vi vet att $E(\bar{X}) = \mu$ (**väntevärdesriktig**) och $SD(\bar{X}) = \sigma/\sqrt{n}$; dessa räkningar använde inte N-fördelning.
- Stora talens lag: *samplingfördelningen för medelvärdet blir alltmer koncentrerad kring μ när stickprovsstorleken n ökar.*

  Mer precist: för varje $a > 0$ (hur litet som helst!) gäller att

$$P(|\bar{X} - \mu| > a) \to 0 \text{ då } n \to \infty.$$

- Vi kan faktiskt bevisa detta med den sannolikhetsteori som vi lärt oss så långt! (Men gör inte det här.)

Stora talens lag - interaktivt



Centrala gränsvärdessatsen

Om $X_1, X_2, \ldots, X_n$ är oberoende från en population med godtycklig fördelning (med ändlig varians σ^2) så är samplingfördelningen för medelvärdet approximativt normalfördelat i stora stickprov:

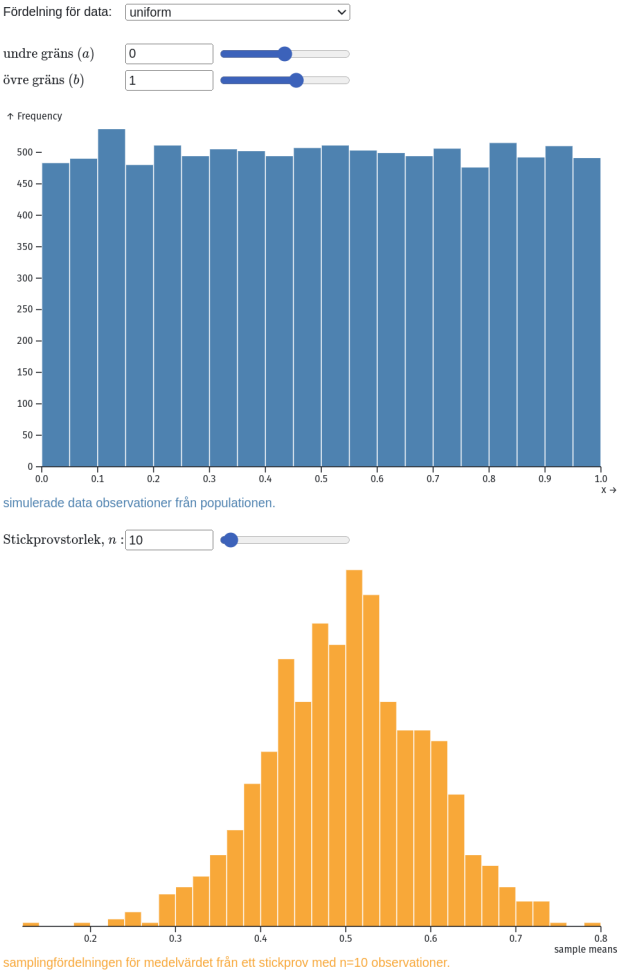
$$\bar{X} \overset{\text{approx}}{\sim} N\left(\mu, \frac{\sigma}{\sqrt{n}}\right) \text{ för tillräckligt stora } n$$

Tumregel: $n \geq 30$ är tillräckligt.

Alternativ (och bättre) formulering:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \overset{\text{approx}}{\sim} N(0,1) \text{ för tillräckligt stora } n$$

Centrala gränsvärdessatsen (CGS) - interaktivt



KI väntevärde - godtycklig population, okänd varians

Antag att $X_1, X_2, \ldots, X_n$ är oberende med väntevärde μ, okänd varians $\sigma^2 < \infty$ och att $n \geq 30$.

Ett approximativt $(1-\alpha)\%$-igt konfidensintervall. för μ är

$$\bar{x} \pm t_{\alpha/2,n-1} \cdot SE(\bar{x}) \quad \text{med} \quad SE(\bar{x}) = s/\sqrt{n},$$

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Konfidensintervall för μ - tre olika situationer

- **Normalpopulation** med **känd varians** σ^2

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- **Normalpopulation** med **okänd varians** skattad med s^2

$$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$$

- **Godtycklig populationsmodell** med **okänd varians** skattad med s^2 och $n \geq 30$ (CGS)

$$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$$

Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo VT 2026 och Tobias Rydén HT 2026