Stockholms universitet

Statistik och dataanalys I – F20

Statistiska institutionen

HT2026

Denna version: 2026-10-21

Innehåll föreläsning 20

- **Glöm inte anmäla er till tentan!**
- **Konfidensintervall** och **hypotesttest** i enkel regression
- **Prediktionsintervall**
- **Inferens i multipel linjär regression**

Standardfel för b_1

- Estimatorn för lutningskoefficienten

$$b_1 = \frac{s_{xy}}{s_x^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

- Hur b_1 varierar mellan olika stickprov:

$$\sigma_{b_1} = SD(b_1) = \frac{\sigma_\varepsilon}{s_x\sqrt{n-1}}$$

- σ_{b_1} skattas med **standardfelet**

$$s_{b_1} = SE(b_1) = \frac{s_e}{s_x\sqrt{n-1}}$$

- Formel för $SE(b_0)$ slipper ni på SDA1.
- `lifespan` data [`sd(spending) = 1.097516`]

$$s_{b_1} = \frac{1.678}{\sqrt{29-1}\cdot 1.097516} \approx 0.289$$

Standardfel för b_1 i R

```
> library(sda123)
> lifespan_no_usa = lifespan[1:29,] # remove the outlier USA
> model = lm(lifespan ~ spending, data = lifespan_no_usa)
> summary(model)

Call:
lm(formula = lifespan ~ spending, data = lifespan_no_usa)

Residuals:
    Min      1Q  Median      3Q     Max
-3.3108 -0.7016 -0.0507  1.1458  3.8860

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  74.1639     0.8782   84.45  < 2e-16 ***
spending      1.7629     0.2890    6.10 1.63e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.678 on 27 degrees of freedom
Multiple R-squared:  0.5795,    Adjusted R-squared:  0.5639
F-statistic: 37.21 on 1 and 27 DF,  p-value: 1.626e-06
```

Samplingfördelning i regression – interaktivt

intercept, β_0 -1

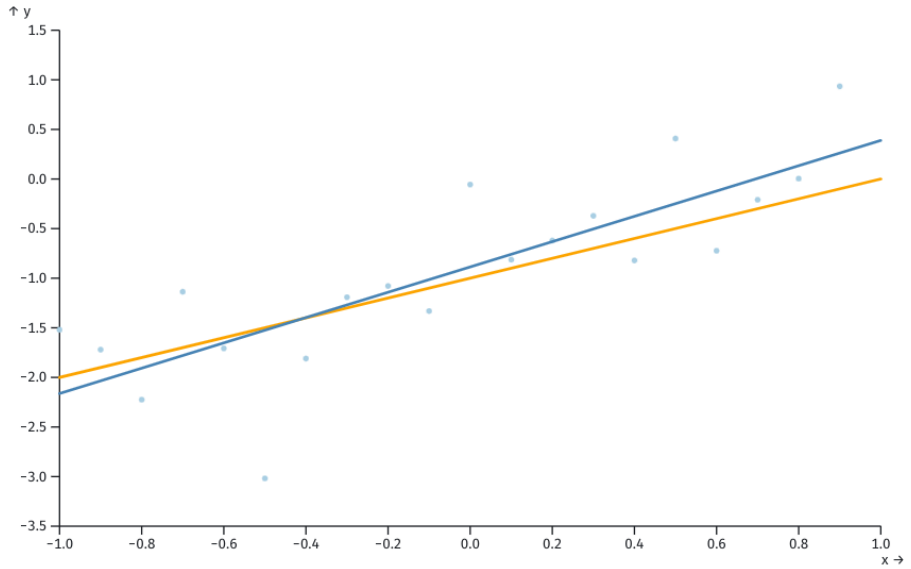
lutning, β_1 1

sd felterm, σ_ε 0.5

Play dataset nummer: 207

Skattat intercept: $b_0 = -0.8866$

Skattad lutning: $b_1 = 1.275$



Populationsmodell

Skattad regressionslinje

Konfidensintervall för b_1

- Den standardiserade estimatorn b_1 följer en t-**fördelning** med $n-2$ **frihetsgrader**:

$$\frac{b_1 - \beta_1}{s_{b_1}} \sim t_{n-2}$$

- Varför $n-2$? Skattar två parametrar, β_0 och β_1. Förlorar två frihetsgrader.
- **95%-igt konfidensintervall** för β_1

$$b_1 \pm t_{0.025,n-2} \cdot s_{b_1}$$

- `lifespan` data: $n = 29$, och $t_{0.025,27} = 2.052$ från tabell.
- 95%-igt konfidensintervall för β_1

$$1.763 \pm 2.052 \cdot 0.289 = (1.170, 2.356)$$

Konfidensintervall i R

- R:

```
> model = lm(lifespan ~ spending, data = lifespan_no_usa) # utan USA
> confint((model))
```

- sda123-paketet:

```
> model = lm(lifespan ~ spending, data = lifespan_no_usa) # utan USA
> reg_summary(model, conf_intervals = TRUE, anova = FALSE)

Measures of model fit
---------------------------------------------
Root MSE       R2   R2-adj
 1.67836  0.57952  0.56394

Parameter estimates
---------------------------------------------
            Estimate Std. Error t value   Pr(>|t|)  2.5 %  97.5 %
(Intercept)  74.1639    0.87822 84.4482 2.9262e-34 72.362 75.9658
spending      1.7629    0.28900  6.1002 1.6256e-06  1.170  2.3559
```

Hypotesttest för β

- **Hypotestest för lutningen** i regressionen

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

- **Teststatistika**

$$T = \frac{b_1 - 0}{s_{b_1}}$$

- Under H_0 har vi att $T \sim t_{n-2}$.
- Vi förkastar nollhypotesten på signifikansnivån $\alpha = 0.05$ om

$$|t_{obs}| > t_{\text{crit}}$$

där det kritiska värdet t_{crit} hämtas från tabell:

$$t_{\text{crit}} = t_{0.025,n-2}$$

- *p*-**värde** räknas som tidigare, men från t_{n-2} fördelning.

Hypotesttest för β – lifespan data

- $n = 29$, så $n - 2 = 27$, och $t_{\text{crit}} = t_{0.025}(27) = 2.052$.

$$t_{\text{obs}} = \frac{1.763 - 0}{0.289} = 6.100$$

- $|t_{\text{obs}}| > t_{\text{crit}}$ så vi **förkastar nollhypotesen** på 5% signifikansnivå.
- Vi förkastar nollhypotesen att `spending` inte är korrelerad med `lifespan`.
- `spending` är en **signifikant förklarande variabel** för livslängd på signifikansnivå 5 %.
- Testets p-värde visar att vi förkastar H_0 på mycket liten signifikansnivå!

$$p = 1.6256\text{E–}06 = 1.6256 \cdot 10^{-6} = 0.0000016256$$

Hypotestest i R

```
> library(sda123)
> lifespan_no_usa = lifespan[1:29,] # remove the outlier USA
> model = lm(lifespan ~ spending, data = lifespan_no_usa)
> summary(model)

Call:
lm(formula = lifespan ~ spending, data = lifespan_no_usa)

Residuals:
    Min      1Q  Median      3Q     Max
-3.3108 -0.7016 -0.0507  1.1458  3.8860

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  74.1639     0.8782   84.45  < 2e-16 ***
spending      1.7629     0.2890    6.10 1.63e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.678 on 27 degrees of freedom
Multiple R-squared:  0.5795,    Adjusted R-squared:  0.5639
F-statistic: 37.21 on 1 and 27 DF,  p-value: 1.626e-06
```

Prediktionsintervall

- Antag att vi gör en prognos vid ett nytt $x = x_\star$

$$\hat{y}_\star = b_0 + b_1 x_\star$$

- **Prediktionsintervall** för $\hat{y}_\star$ – **två källor av osäkerhet**:
  - De **okända parametrarna** β_0 och β_1, dvs osäkerhet om regressionslinjen vid $x_\star$.
  - **Variationen i de enskilda y-värdena kring regressionlinjen**. Alla observationer "träffas av ett ε" med standardavvikelse σ_ε.

- **Prediktionsvariansen**:

$$\sigma^2_{\text{prediktion}} = \sigma^2_{\text{regressionslinjen vid } x_\star} + \sigma^2_\varepsilon$$

- **95%-igt prediktionsintervall** för enskild observation vid $x_\star$

$$\hat{y}_\star \pm t_{0.025,n-2} \cdot \sqrt{\frac{s_e^2}{n} + s_{b_1}^2 (x_\star - \bar{x})^2 + s_e^2}$$

Prediktionsintervall

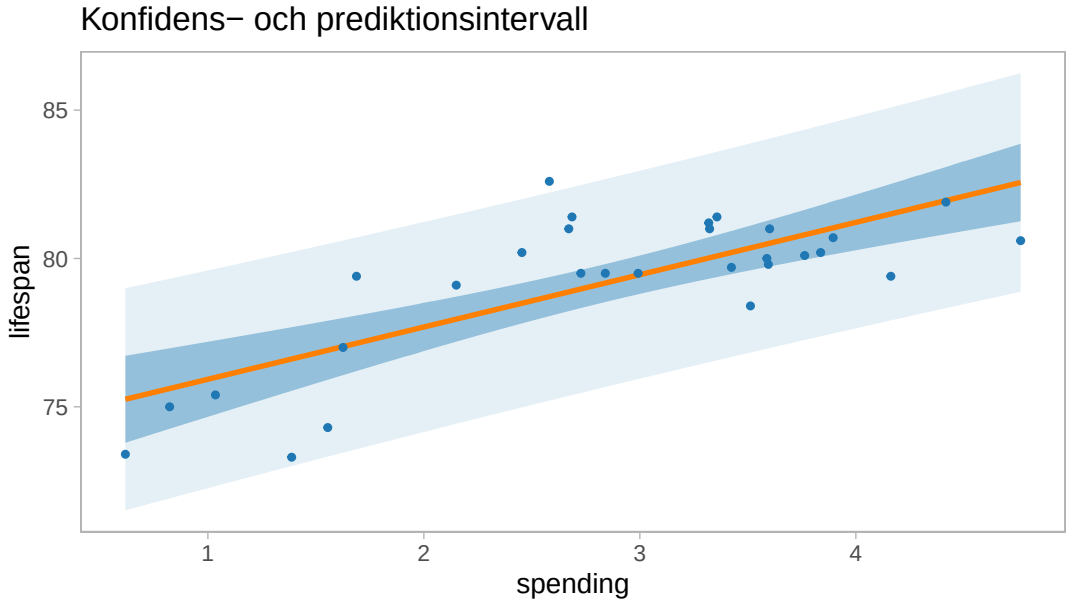
- Intuition för termen $\sigma^2_{\text{regressionslinjen vid } x_\star}$
- Regressionslinjen går alltid genom punkten $(\bar{x}, \bar{y})$
- s_e^2/n representerar osäkerheten i $\bar{Y}$. Notera att x-värdena inte antas slumpmässiga i regression.
- $s_{b_1}^2(x_\star - \bar{x})^2$: Då regressionslinjen går genom $(\bar{x}, \bar{y})$ så blir osäkerheten liten även om lutningen är felskattad ($(x_\star - \bar{x}) \approx 0$). **Längre ifrån medelvärdet**: liten skillnad i lutningen $\Rightarrow$ stor effekt.
- Båda dessa termer skalas med n, så när n blir stort så går de mot 0.
- Detta gäller inte s_e^2!

Prediktionsintervall

```
> model = lm(lifespan ~ spending, data = lifespan_no_usa)
> predict(model, newdata = data.frame(spending = 3.323))
       1
80.02209
> predict(model, newdata = data.frame(spending = 4.323))
       1
81.78502
> predict(model, newdata = data.frame(spending = 4.323), interval = "prediction")
       fit      lwr      upr
1 81.78502 78.17388 85.39616
```

Plot av prediktionsintervall

```
> library(sda123)
> reg_predict(lifespan ~ spending, data = lifespan_no_usa)
```



- Ljusblå band är prediktionsintervall (för ett x i taget).

Multipel regression – modell och samplingfördelning

- **Populationsmodell** för **multipel regression** med k förklarande variabler

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + \varepsilon, \quad \varepsilon \sim N(0, \sigma_\varepsilon)$$

- Varje β_j skattas med b_j med minsta-kvadrat-metoden.
- Den standardiserade estimatorn b_j följer en t-**fördelning** med $n - k - 1$ **frihetsgrader**:

$$\frac{b_j - \beta_j}{s_{b_j}} \sim t_{n-k-1}$$

- Varför $n - k - 1$? Skattar k lutningskoefficienter $(\beta_1, \beta_2, \ldots, \beta_k)$ och ett intercept (β_0).
- Formlerna för minsta-kvadratskattningar b_j och standardfelen s_{b_j} är komplicerade. Datorn får göra jobbet.

Multipel regression – konfidensintervall och test

- **Populationsmodell multipel regression**

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + \varepsilon, \quad \varepsilon \sim N(0, \sigma_\varepsilon)$$

- **95%-igt konfidensintervall** för β_j

$$b_j \pm t_{0.025, n-k-1} \cdot s_{b_j}$$

- **Hypotestest för lutningen** i regressionen

$$H_0 : \beta_j = 0$$

$$H_1 : \beta_j \neq 0$$

- **Teststatistika**

$$T = \frac{b_j - 0}{s_{b_j}}$$

- **Under** H_0 har vi att $T \sim t_{n-k-1}$.
- Om vi **förkastar** H_0 så drar vi slutsatsen att $\beta_j \neq 0$ och säger att x_j **är en signifikant förklarande variabel**.

Multipel regression i R

```
> model = lm(lifespan ~ spending + gdp + doctorvisits, data = lifespan_no_usa)
> summary(model)

Call:
lm(formula = lifespan ~ spending + gdp + doctorvisits, data = lifespan_no_usa)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4860 -0.8975 -0.0762  1.1654  3.7609

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  74.07091    1.34241  55.178  < 2e-16 ***
spending      2.10379    0.55123   3.817 0.000792 ***
gdp          -0.02993    0.04230  -0.708 0.485723
doctorvisits  0.02842    0.10867   0.262 0.795813
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.726 on 25 degrees of freedom
Multiple R-squared:  0.5884,    Adjusted R-squared:  0.5391
F-statistic: 11.92 on 3 and 25 DF,  p-value: 4.894e-05
```

Simulera data med sda123 paketet

```
> library(sda123)
> simdata <- reg_simulate(n = 500, betavect = c(1, -2, 1, 0), sigma_eps = 2)
> head(simdata)
           y          X1         X2          X3
1  1.9710435 -0.02922743 -0.2445304  1.00699482
2 -0.1156157  0.32641792  0.1161198  1.34818268
3  4.2054858  0.40102782  1.5955417 -1.85657317
4  7.3999811 -1.34540553  1.3106342  1.22095959
5  0.4633449 -1.31315970 -0.5062060 -0.08381122
6  2.1395357 -0.30667637 -0.7820189  1.51466922
```

Skatta på simulerat datamaterial

```
> fit = lm(y ~ X1 + X2 + X3, data = simdata)
> summary(fit)

Call:
lm(formula = y ~ X1 + X2 + X3, data = simdata)

Residuals:
    Min      1Q  Median      3Q     Max
-5.5043 -1.2584 -0.0609  1.2501  6.8445

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.21579    0.08731  13.925   <2e-16 ***
X1          -1.98033    0.08854 -22.367   <2e-16 ***
X2           0.88075    0.08493  10.370   <2e-16 ***
X3          -0.02364    0.08639  -0.274    0.784
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.947 on 496 degrees of freedom
Multiple R-squared:  0.5343,    Adjusted R-squared:  0.5315
F-statistic: 189.7 on 3 and 496 DF,  p-value: < 2.2e-16
```

Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo VT 2026, och Tobias Rydén HT 2026.