Stockholms universitet

Statistik och dataanalys I - F22

Statistiska institutionen

HT2026

Denna version: 2026-10-20

Innehåll föreläsning 22

- **Chi2-test för goodness of fit**
- **Chi2-test för oberoende**
- **Beslutsfattande under osäkerhet**

Kortkampanj (Uppgift 22.2 i SDM)

- En bank har tre sorters kreditkort: Silver, Gold och Platinum.
- Marknadsföringkampanj. Skillnad i vilken kortklass kunder ansöker om?
- Undersöker $n = 200$ personers ansökningar efter kampanj.

Korttyp	Innan	Efter	Stickprov efter	Förväntat om ingen effekt av kampanj
Silver	60%	55.5%	111	$200 \cdot 0.6 = 120$
Gold	30%	29.5%	59	$200 \cdot 0.3 = 60$
Platinum	10%	15%	30	$200 \cdot 0.1 = 20$

Chi2-test Goodness-of-fit

- **Räknedata**. Antal.
- **Hypoteser**:
  - H_0: räknedata följer fördelning med sannolikhet $p_k^{(0)}$ i cell k.
  - H_A: räknedata följer annan fördelning.
- Totalt antal i hela tabellen: n
- **Förväntat antal** i cell k : $\text{Exp}_k = n \cdot p_k^{(0)}$.
  - Exempel: $\text{Exp}_{\text{silver}} = 200 \cdot 0.6 = 120$
- **Observerat antal** i cell k : Obs_k
  - Exempel: $\text{Obs}_{\text{silver}} = 111$

Korttyp	Innan	Efter	Stickprov efter	Förväntat om ingen effekt av kampanj
Silver	60%	55.5%	111	$200 \cdot 0.6 = 120$
Gold	30%	29.5%	59	$200 \cdot 0.3 = 60$
Platinum	10%	15%	30	$200 \cdot 0.1 = 20$

Chi2-test Goodness-of-fit

- Hypoteser
  - H_0: räknedata följer fördelning med sannolikhet $p_k^{(0)}$ i cell k.
  - H_A: räknedata följer annan fördelning.

- Chi2 (χ^2) test för tabell med K celler $\Rightarrow$ **teststatistika**:

$$\chi^2 = \sum_{k=1}^{K} \frac{(\text{Obs}_k - \text{Exp}_k)^2}{\text{Exp}_k} = \sum_{\text{all cells}} \frac{(\text{Obs} - \text{Exp})^2}{\text{Exp}}$$

- Under H_0: **Chi2-fördelning** med $K - 1$ frihetsgrader

$$\chi^2 \sim \chi^2_{K-1}$$

Chi2-fördelning

- χ^2-fördelningen kan ses som **summan** av kvadrerade $N(0,1)$ variabler.
- Om vi har $X_1, X_2, \ldots, X_n \sim N(0,1)$ så får vi att:
  - $X_1^2 \sim \chi_1^2$
  - $X_1^2 + X_2^2 \sim \chi_2^2$
  - $\vdots$
  - $X_1^2 + X_2^2 + \cdots + X_n^2 \sim \chi_n^2$
- Antar endast **positiva** värden (kvadrater).
- Är skev åt **höger**.
- Vad händer med formen när vi summerar flera slumpvariabler? (ledtråd: CGS)

Chi2-fördelning

Chi2-fördelningen

Frihetsgrader, ν 4

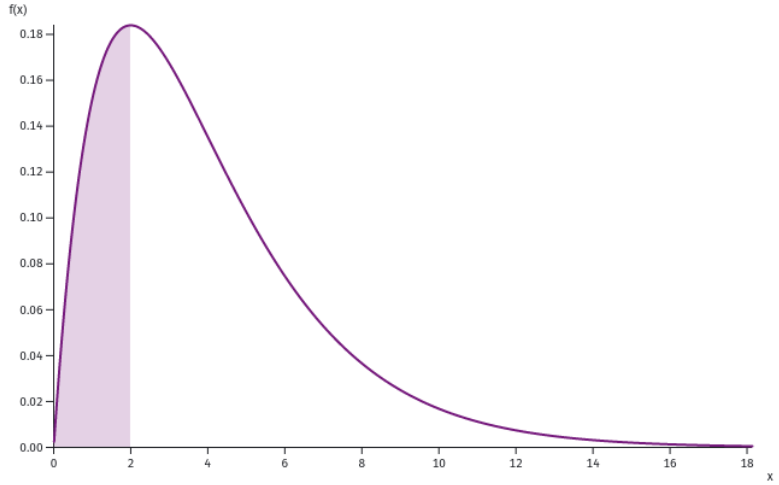
Kvantil: 2

Om $X \sim \chi^2(4)$ så gäller att

$E(X) = \nu = 4.0$

$Var(X) = 2\nu = 8.0$

$P(X \leq 2) = 0.2642$



Mattias Villani Chi2-fördelningen

Observable

Chi2-test Goodness-of-fit

- **Teststatistika**

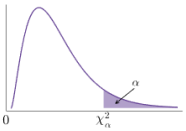
$$\chi^2_{obs} = \sum_{\text{all cells}} \frac{(\text{Obs} - \text{Exp})^2}{\text{Exp}} = \frac{(111-120)^2}{120} + \frac{(59-60)^2}{60} + \frac{(30-20)^2}{20} = 5.6917$$

- **Under H_0 - Chi2-fördelning** med $3 - 1 = 2$ frihetsgrader
- Kritiskt värde på signifikansnivå 5 % från χ^2_2-tabell: $\chi^2_{crit} = 5.991$.
- Eftersom $\chi^2_{obs} < \chi^2_{crit}$ kan vi inte förkasta H_0.
- Finns inte stöd för att kampanjen har ändrat fördelningen över olika kortklasser.

Korttyp	Innan	Efter	Stickprov efter	Förväntat om ingen effekt av kampanj
Silver	60%	55.5%	111	$200 \cdot 0.6 = 120$
Gold	30%	29.5%	59	$200 \cdot 0.3 = 60$
Platinum	10%	15%	30	$200 \cdot 0.1 = 20$

Chi2-tabell

χ^2-fördelning



Right-tail probability:	0.100	0.050	0.025	0.010	0.005
df					
1	2.706	3.841	5.024	6.635	7.879
2	4.605	5.991	7.378	9.210	10.597
3	6.251	7.815	9.348	11.345	12.838
4	7.779	9.488	11.143	13.277	14.860
5	9.236	11.070	12.833	15.086	16.750
6	10.645	12.592	14.449	16.812	18.548
7	12.017	14.067	16.013	18.475	20.278
8	13.362	15.507	17.535	20.090	21.955
9	14.684	16.919	19.023	21.666	23.589
10	15.987	18.307	20.483	23.209	25.188
11	17.275	19.675	21.920	24.725	26.757
12	18.549	21.026	23.337	26.217	28.300
13	19.812	22.362	24.736	27.688	29.819
14	21.064	23.685	26.119	29.141	31.319
15	22.307	24.996	27.488	30.578	32.801
16	23.542	26.296	28.845	32.000	34.267
17	24.769	27.587	30.191	33.409	35.718
18	25.989	28.869	31.526	34.805	37.156
19	27.204	30.144	32.852	36.191	38.582
20	28.412	31.410	34.170	37.566	39.997
21	29.615	32.671	35.479	38.932	41.401
22	30.813	33.924	36.781	40.289	42.796
23	32.007	35.172	38.076	41.638	44.181
24	33.196	36.415	39.364	42.980	45.559
25	34.382	37.652	40.646	44.314	46.928
26	35.563	38.885	41.923	45.642	48.290
27	36.741	40.113	43.195	46.963	49.645
28	37.916	41.337	44.461	48.278	50.993

Test av oberoende - Hepatit C

	Hepatit C	Ej hepatit C	Total
Tatuering, studio	17	35	52
Tatuering, ej studio	8	53	61
Ingen tatuering	22	491	513
Total	47	579	626

- Hur skulle tabellen ovan skulle se ut om det **inte fanns något samband**?
- 47 av 626 personer testade positivt för hepatit C.
- Om hepatit C och tatueringsstatus är oberoende så borde andelen vara runt $47/626 = 0.075$ oavsett om personen var tatuerad eller inte.

Test av oberoende - Hepatit C

	Hepatit C	Ej hepatit C	Total
Tatuering, studio	17	35	52
Tatuering, ej studio	8	53	61
Ingen tatuering	22	491	513
Total	47	579	626

- $52/626 = 0.08$ har en tatuering från en tatueringsstudio. Av dessa 52 skulle vi förvänta oss att $52 * 47/626 = 3.9$ skulle ha hepatit C, om det inte finns något samband. Resten $(52 - 3.9 = 48.1)$ förväntas ej ha heptatit C.

- Av dom 61 som har en tatuering, men inte från en tatueringsstudio, förväntar vi oss $61 * 47/626 = 4.6$ med hepatit C och $61 - 4.6 = 56.4$ utan hepatit C.

- Vi beräknar de 6 förväntade antalen om det ej finns samband och jämför med observerade data.

Test av oberoende – allmänt fall

Data (J rader, K kolumner)				
x_{11}	x_{12}	$\cdots$	x_{1K}	$n_{1\cdot}$
x_{21}	x_{22}	$\cdots$	x_{2K}	$n_{2\cdot}$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
x_{J1}	x_{J2}	$\cdots$	x_{JK}	$n_{J\cdot}$
$n_{\cdot 1}$	$n_{\cdot 2}$	$\cdots$	$n_{\cdot K}$	n

- Nollhypotesen H_0 är oberoende mellan kategorier per rad och kolumn: $p_{ij} = r_i c_j$ för några sannolikhetsfördelningar r_i (rad) respektive c_j (kolumn).
- Under H_0 estimerar vi $\hat{r}_i = n_{i\cdot}/n$ och $\hat{c}_j = n_{\cdot j}/n$.
- Under H_0 är förväntat antal observationer i cell $(i, j) = n\, r_i c_j$. Detta estimeras med:

$$\text{Exp}_{ij} = n\,\hat{r}_i\hat{c}_j = n \times \frac{n_{i\cdot}}{n} \times \frac{n_{\cdot j}}{n} = \frac{n_{i\cdot} \times n_{\cdot j}}{n}.$$

Test av oberoende - Hepatit C

	Hepatit C	Obs	Exp	$\frac{(Obs-Exp)^2}{Exp}$
Studio	Ja	17	3.9	44.0
Studio	Nej	35	48.1	3.6
Ej studio	Ja	8	4.6	2.5
Ej studio	Nej	53	56.4	0.2
Ingen	Ja	22	38.5	7.1
Ingen	Nej	491	474.5	0.6

- Den totala avvikelsen är 58.0. Är denna avvikelse från vad vi förväntar oss tillräckligt stor för att vi ska förkasta antagandet om oberoende? Vi gör ett hypotestest!

Test av oberoende - Hepatit C

- **Hypoteser**:
  - H_0: de två variablerna (tatueringsstatus och hepatit C i detta exempel) är oberoende.
  - H_A: dom två variablerna är inte oberoende.
- **Teststatistika** $\chi^2 = \sum_{alla} \frac{(Obs - Exp)^2}{Exp}$.
- **Antal frihetsgrader**: $df = (n_{rader} - 1) \cdot (n_{kolumner} - 1)$.
- **Kritiskt värde**: $\chi^2_{df}(\alpha)$.
- **Förkasta** om $\chi^2_{obs} > \chi^2_{df}(\alpha)$.

Test av oberoende - Hepatit C

- **Hypoteser**:
  - H_0: de två variablerna (tatueringsstatus och hepatit C i detta exempel) är oberoende.
  - H_A: de två variablerna är inte oberoende.

- **Teststatistika**: $\chi^2_{obs} = \sum_{alla} \frac{(Obs-Exp)^2}{Exp} = 58.0.$

- **Antal frihetsgrader**:
  $df = (n_{rader} - 1) \cdot (n_{kolumner} - 1) = (3-1) \cdot (2-1) = 2.$

- **Kritiskt värde**, vi väljer $\alpha = 0.05 : \chi^2_2(0.05) = 5.991.$
- $\chi^2_{obs} = 58 > 5.991$. Vi förkastar nollhypotesen på $\alpha = 0.05$ signifikansnivå.

Test av oberoende - antaganden

- **Räknedata**: Vi antar att vi har räknedata för individer, med värden för två variabler.
- **Oberoende**: Vi antar att observationerna är oberoende, exempelvis ett slumpmässigt urval.
- **Tillräcklig cellfrekvens**: vi antar att det förväntade antalet (Exp) är minst 5 i varje cell.

Test av oberoende - kollaps

- För hepatitexemplet så är inte det tredje antagandet uppfyllt, så vi bör vara försiktiga med våra slutsatser. Ett alternativ är att kollapsa olika kategorier. Lägsta förväntade blir då $113 \cdot 47/626 = 8.5$, men vi tappar möjligheten att se om det är nån skillnad mellan tatuering i studio eller övrig tatuering.

	Hepatit C	Ej hepatit C	Total
Tatuering	25	88	113
Ej tatuering	22	491	513
Total	47	579	626

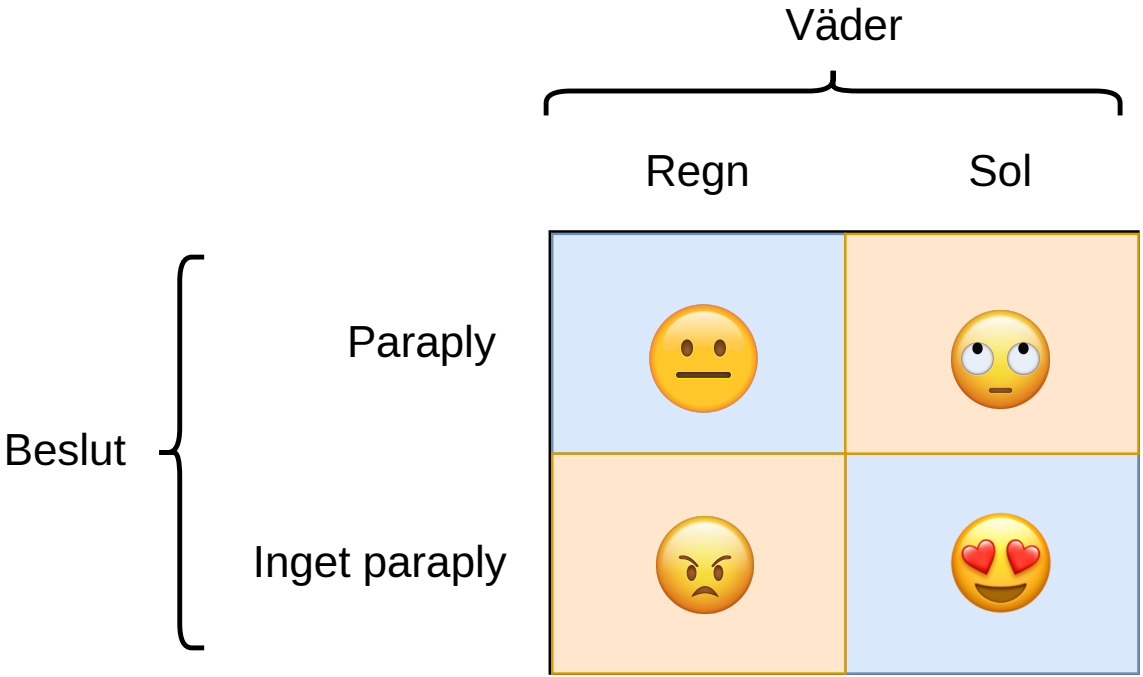
Beslut under osäkerhet

- Vi behöver ofta **fatta beslut** i en miljö med **osäkerhet**.
  - **Beslut**: ska jag ta med ett paraply när jag går ut?
  - **Osäkerhet**: kommer det att regna?
  - **Beslut**: ska jag investera i aktier eller spara på banken?
  - **Osäkerhet**: börsens och inflationens utveckling under min placeringshorisont.
  - **Beslut**: ska Sverige satsa på snabbtåg?
  - **Osäkerhet**: hur kommer elbilar utvecklas? Klimatet? Vad kommer det kosta? etc.

Beslut och statistik

- Ett fattat beslut har **konsekvenser**.
- **Konsekvenserna beror på osäkra faktorer** som vi inte vet när vi fattar beslutet.
- Vi behöver **sannolikhetfördelningen** för de osäkra kvantiteterna.
- Modellerar **osäker kvantitet** i form av en slumpvariabel X.
- Använder **data** (och expertkunskap) för att beräkna dessa sannolikheter. **Statistik**!

Beslut + Utfall = Konsekvens



Nyttobegreppet

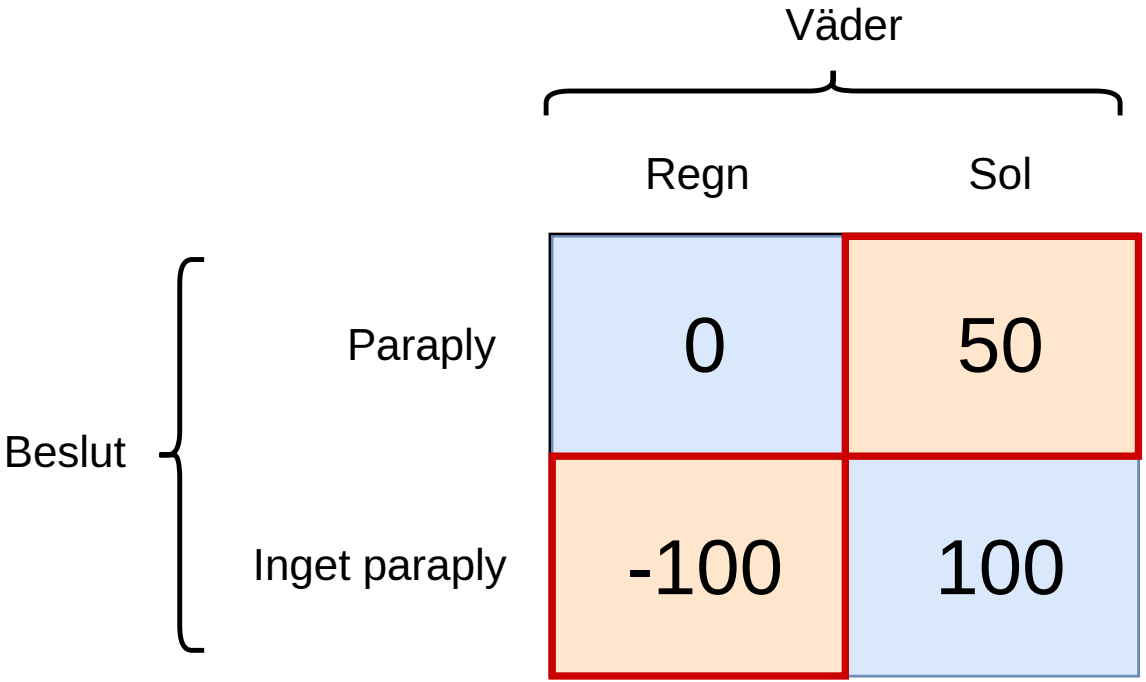
- **Beslutsprocess**:
  - Du **fattar beslutet** a.
  - X **realiseras** som x.
  - Kombinationen a och x ger dig viss **nytta** (eng. **utility**):

$$U(a, x)$$

- Ibland: **förlust** $L(a, x)$ - vilket bara är negativ nytta

$$L(a, x) = -U(a, x)$$

Nytta



Maximin - en pessimistisk beslutsregel

- **Maximin**: välj beslut a som maximerar den minimala nyttan.
- **Garderar mot det värsta** som kan hända (pessimist).

Beslut	Väder: Regn	Väder: Sol
Paraply	0	50
Inget paraply	-100	100

- Maximin ignorerar hur sannolika utfallen är.

Beslut	Väder: Regn (0.2)	Väder: Sol (0.8)
Paraply	0	50
Inget paraply	-100	100

Beslut	Väder: Regn (0.01)	Väder: Sol (0.99)
Paraply	0	50
Inget paraply	-100	100

- I **spelteori** med **intelligent motståndare** är maximin optimal.

Maximera förväntad nytta

- **Beslutsregel** välj beslut a som maximerar förväntade nytta

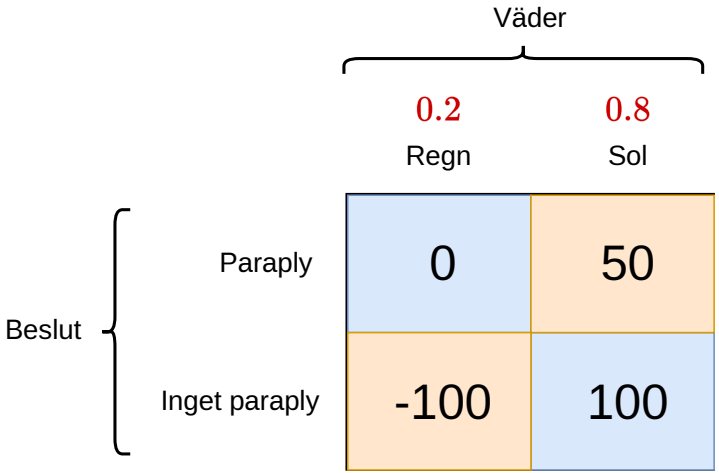
$$\mathrm{E}[U(a, X)] = \sum_{\text{alla } x} U(a, x) \cdot P(X = x)$$

- **Paraply-beslutet**:

$$a_1 = \text{Paraply} : \mathrm{E}[U(a, X)] = 0.2 \cdot 0 + 0.8 \cdot 50 = 40$$

$$a_2 = \text{Inget paraply} : \mathrm{E}[U(a, X)] = 0.2 \cdot (-100) + 0.8 \cdot 100 = 60$$

- **Optimalt beslut**: ta inte med paraply.



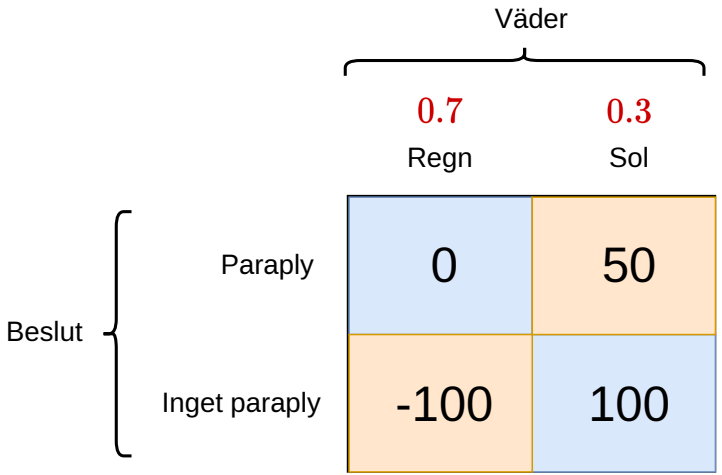
Maximera förväntad nytta

- **Paraply-beslutet** i Bergen:

$$a_1 = \text{Paraply} : \mathrm{E}[U(a, X)] = 0.7 \cdot 0 + 0.3 \cdot 50 = 15$$

$$a_2 = \text{Inget paraply} : \mathrm{E}[U(a, X)] = 0.7 \cdot (-100) + 0.3 \cdot 100 = -40$$

- **Optimal beslut** i Bergen: Paraply!



Credits

Dessa slides är gjorda utifrån slides som skapades för kursen statistik och dataanalys 1 av Mattias Villani HT 2023, och har modifierats av Oscar Oelrich VT 2024, Oskar Gustafsson för VT 2025, Jonas Bjermo för VT 2026 och Tobias Rydén för HT 2026.